

Análisis de Correspondencias Simples

Teoría paso a paso — construido desde cero en R

Tutorial teórico

2026-06-27

Tabla de contenidos

1	Descripción del método	2
1.1	Los datos del ejemplo	2
2	Tablas de contingencia y perfiles	3
2.1	Tabla de frecuencias relativas P	3
2.2	Masas de fila r y de columna c	3
2.3	Perfiles fila	4
2.4	Perfiles columna	6
3	Inercia y distancia χ^2	6
3.1	Distancia chi-cuadrado entre perfiles	6
3.2	Frecuencias esperadas bajo independencia	7
3.3	Chi-cuadrado de Pearson	7
3.4	Inercia total	8
4	Obtención de los factores	9
4.1	La matriz S — núcleo del ACS	9
4.2	Descomposición en Valores Singulares (SVD)	10
4.3	Coordenadas principales	11
4.4	Calidad de representación ($\cos^2$)	12
4.5	Contribuciones absolutas	13
5	Mapa de correspondencias	15
5.1	Cómo leer el mapa — 5 reglas de oro	16
5.2	Interpretación del ejemplo	17
6	Resumen estadístico	17

1. Descripción del método

El **Análisis de Correspondencias Simples (ACS)** es una técnica de estadística multivariada que permite explorar y visualizar la **asociación entre dos variables cualitativas** (categóricas).

La idea central es sencilla: dada una tabla de contingencia, queremos saber si las filas y las columnas son independientes entre sí, y si no lo son, queremos **ver gráficamente** cuáles categorías se asocian.

i Pregunta que responde el ACS

¿Existe asociación entre la **edad** de una persona y la **bebida** que prefiere? Y si existe, ¿qué edades se asocian con qué bebidas?

El ACS produce un **mapa de baja dimensión** (usualmente 2D) donde las categorías de filas y columnas aparecen como puntos. La **proximidad** entre un punto-fila y un punto-columna indica asociación.

1.1. Los datos del ejemplo

Usaremos una encuesta de preferencia de bebidas según grupo de edad:

```
N <- matrix(
  c(50, 25, 10,
    30, 60, 20,
    10, 45, 70),
  nrow = 3, byrow = TRUE,
  dimnames = list(
    edad = c("Joven", "Adulto", "Mayor"),
    bebida = c("Refresco", "Cafe", "Te")
  )
)

n_total <- sum(N)
knitr::kable(N, caption = paste("Tabla de contingencia. Total: n =", n_total))
```

Tabla 1: Tabla de contingencia. Total: n = 320

	Refresco	Cafe	Te
Joven	50	25	10

	Refresco	Cafe	Te
Adulto	30	60	20
Mayor	10	45	70

Cada celda n_{ij} es el número de personas del grupo de edad i que prefirieron la bebida j .

2. Tablas de contingencia y perfiles

2.1. Tabla de frecuencias relativas P

El primer paso es convertir la tabla de conteos en **proporciones**. Definimos:

$$p_{ij} = \frac{n_{ij}}{n}$$

donde $n = \sum_{i,j} n_{ij}$ es el total general. La tabla P representa la **distribución de probabilidad conjunta empírica**.

```
P <- N / n_total
knitr::kable(round(P, 4), caption = "Tabla P = N/n (frecuencias relativas)")
```

Tabla 2: Tabla P = N/n (frecuencias relativas)

	Refresco	Cafe	Te
Joven	0.1562	0.0781	0.0312
Adulto	0.0938	0.1875	0.0625
Mayor	0.0312	0.1406	0.2188

2.2. Masas de fila r y de columna c

Las **masas** son las marginales de P .

$$r_i = \sum_j p_{ij} = \frac{n_{i.}}{n}, \quad c_j = \sum_i p_{ij} = \frac{n_{.j}}{n}$$

Representan el “peso” o importancia de cada categoría. Una fila con masa grande tendrá más influencia en el análisis.

```
r <- rowSums(P)
c <- colSums(P)

cat("Masas fila r_i:\n"); print(round(r, 4))
```

Masas fila r_i:

	Joven	Adulto	Mayor
	0.2656	0.3438	0.3906

```
cat("\nMasas columna c_j:\n"); print(round(c, 4))
```

Masas columna c_j:

	Refresco	Cafe	Te
	0.2812	0.4062	0.3125

2.3. Perfiles fila

El **perfil fila** de la fila i es su distribución condicional de columnas:

$$f_{ij} = \frac{p_{ij}}{r_i}$$

Responde: *‘‘Dado que la persona es del grupo* i , ¿qué proporción elige cada bebida?’’

En forma matricial: $\mathbf{F}_{perfiles} = D_r^{-1}\mathbf{P}$, donde $D_r = \text{diag}(r)$.

```
Dr_inv <- diag(1 / r)
F_perfiles <- Dr_inv %*% P
rownames(F_perfiles) <- rownames(N)
colnames(F_perfiles) <- colnames(N)

knitr::kable(round(F_perfiles, 4),
              caption = "Perfiles fila (distribución condicional de bebida dado edad)")
```

Tabla 3: Perfiles fila (distribución condicional de bebida dado edad)

	Refresco	Cafe	Te
Joven	0.5882	0.2941	0.1176
Adulto	0.2727	0.5455	0.1818
Mayor	0.0800	0.3600	0.5600

! Idea clave

Si **no hubiera asociación**, todos los perfiles fila serían **iguales** al perfil promedio (las masas de columna c). La desviación de los perfiles respecto a c es exactamente lo que el ACS analiza.

```
cat("Perfil promedio (masas de columna c):\n")
```

Perfil promedio (masas de columna c):

```
print(round(c, 4))
```

```
Refresco      Cafe      Te
0.2812      0.4062      0.3125
```

```
cat("\nPerfil fila de 'Joven':\n")
```

Perfil fila de 'Joven':

```
print(round(F_perfiles["Joven", ], 4))
```

```
Refresco      Cafe      Te
0.5882      0.2941      0.1176
```

```
cat("\n→ Joven consume Refresco:", round(F_perfiles["Joven","Refresco"],3),
    " vs promedio:", round(c["Refresco"],3), "← ¡asociación!")
```

→ Joven consume Refresco: 0.588 vs promedio: 0.281 ← ¡asociación!

2.4. Perfiles columna

De forma simétrica, el **perfil columna** de la columna j es:

$$g_{ij} = \frac{p_{ij}}{c_j}$$

En forma matricial: $\mathbf{G}_{perfiles} = \mathbf{P} \mathbf{D}_c^{-1}$.

```
Dc_inv      <- diag(1 / c)
G_perfiles <- P %*% Dc_inv
rownames(G_perfiles) <- rownames(N)
colnames(G_perfiles) <- colnames(N)

knitr::kable(round(G_perfiles, 4),
              caption = "Perfiles columna (distribución condicional de edad dado bebida)")
```

Tabla 4: Perfiles columna (distribución condicional de edad dado bebida)

	Refresco	Cafe	Te
Joven	0.5556	0.1923	0.1
Adulto	0.3333	0.4615	0.2
Mayor	0.1111	0.3462	0.7

3. Inercia y distancia χ^2

3.1. Distancia chi-cuadrado entre perfiles

Para medir qué tan *diferentes* son dos perfiles fila i e i' , el ACS usa la **distancia chi-cuadrado**:

$$d_{\chi^2}^2(i, i') = \sum_j \frac{(f_{ij} - f_{i'j})^2}{c_j}$$

La división por c_j es crucial: una diferencia en una columna con masa pequeña (categoría rara) se penaliza **más** que la misma diferencia en una columna frecuente. Esto da más importancia a las asociaciones con categorías poco comunes.

3.2. Frecuencias esperadas bajo independencia

Si las variables fueran **independientes**, esperaríamos:

$$e_{ij} = n \cdot r_i \cdot c_j$$

```
E <- outer(r, c) * n_total
knitr::kable(round(E, 2),
              caption = "Frecuencias esperadas E bajo independencia")
```

Tabla 5: Frecuencias esperadas E bajo independencia

	Refresco	Cafe	Te
Joven	23.91	34.53	26.56
Adulto	30.94	44.69	34.38
Mayor	35.16	50.78	39.06

3.3. Chi-cuadrado de Pearson

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

Observada Esperada

¿Existe relación entre bebida y rango de edad?

$e_{ij} = n \cdot r_i \cdot c_j$ $P(\text{baseosa})$
 $P(\text{Adulto})$

```
chi2 <- sum((N - E)^2 / E)
gl <- (nrow(N) - 1) * (ncol(N) - 1) 2x2=4
p_val <- pchisq(chi2, df = gl, lower.tail = FALSE)
inercia_total <- chi2 / n_total
cat(sprintf("Chi-cuadrado = %.4f\n", chi2))
```

Chi-cuadrado = 95.8875

```
cat(sprintf("Grados de libertad = %d\n", gl))
```

Grados de libertad = 4

```
cat(sprintf("p-value = %s\n", format(p_val, scientific = TRUE, digits = 3)))
```

p-value = 7.38e-20

```
cat(sprintf("Inercia total = Chi^2/n = %.6f\n", inercia_total))
```

Inercia total = χ^2/n = 0.299648

Inercia = 0 $\rightarrow$ Independencia perfecta
Inercia pequeña $\rightarrow$ Poca asociación
Inercia grande $\rightarrow$ Mayor asociación

3.4. Inercia total

La **inercia total** es la medida global de asociación en el ACS:

$$\phi^2 = \frac{\chi^2}{n} = \sum_i \sum_j \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}$$

Mientras mayor sea la inercia, más diferentes son los perfiles entre sí (más asociación hay).

```
residuos <- (N - E)^2 / E  
knitr::kable(round(residuos, 3),  
              caption = "Contribución de cada celda al Chi-cuadrado (residuos)")
```

Tabla 6: Contribución de cada celda al Chi-cuadrado (residuos)

	Refresco	Cafe	Te
Joven	28.481	2.631	10.327
Adulto	0.028	5.247	6.011
Mayor	18.001	0.658	24.503

Las celdas con **valores altos** son las más “sorprendentes” respecto a la independencia — son las que generan la asociación.

Chi-Cuadrado
Inercia total

4. Obtención de los factores

4.1. La matriz S — núcleo del ACS

Para aplicar la SVD necesitamos construir una matriz que capture la asociación de forma estandarizada. Definimos:

$$S_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}$$

Masas filas Masas columnas
Asociación $r_i = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$

En forma matricial:

$$D_r^{-1/2} = \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix}^{-1/2}$$

$$S = D_r^{-1/2} (P - rc^T) D_c^{-1/2}$$

donde rc^T es la tabla de independencia (producto externo de las masas).

```
Dr_sqrt_inv    <- diag(1 / sqrt(r))
Dc_sqrt_inv    <- diag(1 / sqrt(c))
P_independencia <- outer(r, c)

S <- Dr_sqrt_inv %*% (P - P_independencia) %*% Dc_sqrt_inv

knitr::kable(round(S, 6), caption = "Matriz S de residuos estandarizados")
```

Tabla 7: Matriz S de residuos estandarizados

0.298336	-0.090671	-0.179646
-0.009422	0.128050	-0.137060
-0.237175	-0.045352	0.276713

```
# Verificación
cat(sprintf("\nVerificación: sum(S^2) = %.6f == inercia total = %.6f",
            sum(S^2), inercia_total))
```

Verificación: sum(S²) = 0.299648 == inercia total = 0.299648

💡 ¿Por qué funciona esta estandarización?

La suma $\sum_{ij} S_{ij}^2$ es exactamente la inercia total ϕ^2 . Toda la información sobre la asociación queda comprimida en S .

Clave

4.2. Descomposición en Valores Singulares (SVD)

El ACS descompone S como:

$$\mathbf{S} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$$

donde:

- $\mathbf{U}$: vectores singulares izquierdos ($I \times K$) — relacionados con las filas
 - $\mathbf{D}$: matriz diagonal de **valores singulares** λ_k
 - $\mathbf{V}$: vectores singulares derechos ($J \times K$) — relacionados con las columnas
- Los **valores propios** λ_k^2 son la inercia explicada por cada eje. El número máximo de ejes es $\min(I - 1, J - 1)$.

```
svd_S <- svd(S)

lambda      <- svd_S$d
U           <- svd_S$u
V           <- svd_S$v
valores_propios <- lambda^2
pct          <- valores_propios / sum(valores_propios) * 100

cat("Valores singulares _k:\n")
```

Valores singulares _k:

```
print(round(lambda, 6))
```

```
[1] 0.504781 0.211764 0.000000
```

```
cat("\nValores propios _k^2 (inercia por eje):\n")
```

Valores propios λ_k^2 (inercia por eje):

```
print(round(valores_propios, 6))
```

```
[1] 0.254804 0.044844 0.000000
```

```
cat("\nInercia explicada por eje:\n")
```

Inercia explicada por eje:

```
for (k in seq_along(pct)) {  
  if (pct[k] > 0.01)  
    cat(sprintf(" Eje%d:  $\lambda^2$  = %.6f  $\rightarrow$  %.2f%% de la inercia\n",  
                k, valores_propios[k], pct[k]))  
}
```

Eje 1: λ^2 = 0.254804 $\rightarrow$ 85.03% de la inercia

Eje 2: λ^2 = 0.044844 $\rightarrow$ 14.97% de la inercia

```
cat(sprintf(" Acumulado ejes 1+2: %.2f%%\n", sum(pct[1:2])))
```

Acumulado ejes 1+2: 100.00%

4.3. Coordenadas principales

Una vez obtenida la SVD, “deshacemos” el escalado para obtener las posiciones reales de cada categoría.

Coordenadas principales de filas (**F**):

$$\mathbf{F} = D_r^{-1/2} \mathbf{U} \mathbf{D} \Rightarrow F_{ik} = \frac{u_{ik} \lambda_k}{\sqrt{r_i}}$$

Vectores singulares izquierdos filas

Coordenadas principales de columnas (**G**):

$$\mathbf{G} = D_c^{-1/2} \mathbf{V} \mathbf{D} \Rightarrow G_{jk} = \frac{v_{jk} \lambda_k}{\sqrt{c_j}}$$

Vectores singulares derechos columnas

```

K <- 2

F_coord <- Dr_sqrt_inv %*% U[, 1:K] %*% diag(lambda[1:K])
G_coord <- Dc_sqrt_inv %*% V[, 1:K] %*% diag(lambda[1:K])

rownames(F_coord) <- rownames(N)
rownames(G_coord) <- colnames(N)
colnames(F_coord) <- colnames(G_coord) <- c("Dim1", "Dim2")

knitr::kable(round(F_coord, 4), caption = "Coordenadas principales - Filas (grupos de edad)")

```

Tabla 8: Coordenadas principales — Filas (grupos de edad)

	Dim1	Dim2
Joven	-0.6642	0.2153
Adulto	-0.1436	-0.2863
Mayor	0.5780	0.1056

Coordenadas

```

knitr::kable(round(G_coord, 4), caption = "Coordenadas principales - Columnas (bebidas)")

```

Tabla 9: Coordenadas principales — Columnas (bebidas)

	Dim1	Dim2
Refresco	-0.6986	0.1694
Cafe	0.0120	-0.2560
Te	0.6131	0.1803

Coordenadas

```

# Verificación de inercia
inercia_eje1 <- sum(r * F_coord[,1]^2)
cat(sprintf("\nVerificación eje 1:  $\sum r_i \cdot F_{i1}^2 = %.6f == 1^2 = %.6f$ ",
            inercia_eje1, valores_propios[1]))

```

Verificación eje 1: $\sum r_i \cdot F_{i1}^2 = 0.254804 == 1^2 = 0.254804$

4.4. Calidad de representación ($\cos^2$) Se puede calcular solo con coordenadas

No todos los puntos quedan bien representados en el plano 2D. El $\cos^2$ mide qué proporción de la inercia propia del punto queda capturada:

$$\cos^2_{ik} = \frac{F_{ik}^2}{\sum_k F_{ik}^2}$$

Un valor cercano a 1 indica representación excelente. Un valor cercano a 0 indica que el punto está “escondido” fuera del plano y debe interpretarse con cautela.

```
F_completo <- Dr_sqrt_inv %*% U %*% diag(lambda)
G_completo <- Dc_sqrt_inv %*% V %*% diag(lambda)
rownames(F_completo) <- rownames(N)
rownames(G_completo) <- colnames(N)

dist2_filas <- rowSums(F_completo^2)
dist2_cols <- rowSums(G_completo^2)

cos2_filas <- F_coord^2 / dist2_filas
cos2_cols <- G_coord^2 / dist2_cols

knitr::kable(round(cos2_filas, 4), caption = "cos² filas (entre 0 y 1; cerca de 1 = bien repr")
```

Tabla 10: cos² filas (entre 0 y 1; cerca de 1 = bien representado)

	Dim1	Dim2
Joven	0.9050	0.0950
Adulto	0.2010	0.7990
Mayor	0.9677	0.0323

```
knitr::kable(round(cos2_cols, 4), caption = "cos² columnas")
```

Tabla 11: cos² columnas

	Dim1	Dim2
Refresco	0.9445	0.0555
Cafe	0.0022	0.9978
Te	0.9204	0.0796

4.5. Contribuciones absolutas

La **contribución absoluta** de la fila i al eje k mide cuánto “construye” ese punto al eje:

$$ctr_{ik} = \frac{r_i \cdot F_{ik}^2}{\lambda_k^2} \text{ Valores propios.}$$

La suma de contribuciones en cada eje es exactamente 1. Un punto con contribución mayor a $1/I$ (el umbral uniforme) es importante para ese eje.

```
ctr_filas <- t(apply(F_coord^2 * r, 1, function(x) x / valores_propios[1:K]))
ctr_col <- t(apply(G_coord^2 * c, 1, function(x) x / valores_propios[1:K]))
colnames(ctr_filas) <- colnames(ctr_col) <- c("Dim1", "Dim2")
rownames(ctr_filas) <- rownames(N)
rownames(ctr_col) <- colnames(N)

knitr::kable(round(ctr_filas, 4),
              caption = "Contribuciones absolutas - Filas (suma por columna = 1)")
```

Tabla 12: Contribuciones absolutas — Filas (suma por columna = 1)

	Dim1	Dim2
Joven	0.4599	0.2745
Adulto	0.0278	0.6284
Mayor	0.5123	0.0971

```
cat("Verificación sumas por eje:", round(colSums(ctr_filas), 4), "\n")
```

Verificación sumas por eje: 1 1

```
knitr::kable(round(ctr_col, 4),
              caption = "Contribuciones absolutas - Columnas")
```

Tabla 13: Contribuciones absolutas — Columnas

	Dim1	Dim2
Refresco	0.5387	0.1800
Cafe	0.0002	0.5935
Te	0.4610	0.2265

```
cat(sprintf("Umbral de importancia para filas: 1/%d = %.3f\n", nrow(N), 1/nrow(N)))
```

Umbral de importancia para filas: 1/3 = 0.333

5. Mapa de correspondencias

El **mapa de correspondencias** (biplot) es la visualización central del ACS. Filas y columnas se grafican juntas en el mismo espacio de coordenadas principales.

```
df_filas <- data.frame(
  nombre = rownames(F_coord),
  Dim1   = F_coord[, 1],
  Dim2   = F_coord[, 2],
  tipo   = "Edad"
)
df_cols <- data.frame(
  nombre = rownames(G_coord),
  Dim1   = G_coord[, 1],
  Dim2   = G_coord[, 2],
  tipo   = "Bebida"
)
df_todo <- rbind(df_filas, df_cols)

titulo_x <- sprintf("Dimensión 1  (%.1f%% de inercia)", pct[1])
titulo_y <- sprintf("Dimensión 2  (%.1f%% de inercia)", pct[2])

ggplot(df_todo, aes(x = Dim1, y = Dim2, color = tipo, shape = tipo)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray70") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "gray70") +
  geom_point(size = 4.5) +
  geom_text(aes(label = nombre), vjust = -0.9, fontface = "bold", size = 4.5) +
  scale_color_manual(values = c("Edad" = "#C00000", "Bebida" = "#2E75B6")) +
  scale_shape_manual(values = c("Edad" = 17, "Bebida" = 16)) +
  labs(
    title      = "Mapa de Correspondencias Simples",
    subtitle   = " Grupos de edad  (rojo)      Bebidas  (azul)",
    x = titulo_x, y = titulo_y,
    color = NULL, shape = NULL
```

```

) +
theme_minimal(base_size = 13) +
theme(
  plot.title = element_text(face = "bold", hjust = 0.5),
  plot.subtitle = element_text(hjust = 0.5, color = "gray50"),
  legend.position = "none"
)

```




Figura 1: Mapa de Correspondencias Simples: Edad × Bebida

5.1. Cómo leer el mapa — 5 reglas de oro

Regla	Qué observar	Cómo interpretarlo
1. Proximidad	Distancia fila columna	Cuanto más cerca, más fuerte la asociación
2. El origen	El punto (0, 0)	Representa el <i>perfil promedio</i> — sin asociación especial
3. $\cos^2$	Calidad de representación	Solo interpreta si $\cos^2 > 0.5$ en ese eje
4. Contribución	Quién “construye” cada eje	Puntos con $\text{ctr} > 1/I$ definen el eje
5. No distancias fila-fila	Distancias entre misma clase	Solo fila columna tiene sentido geométrico

5.2. Interpretación del ejemplo

- **Joven** se aleja hacia **Refresco** → los jóvenes consumen más refrescos de lo esperado
- **Mayor** se aleja hacia **Té** → los mayores beben más té de lo esperado
- **Adulto** queda cerca de **Café** → los adultos se asocian con el café
- El **Eje 1** (85 %) separa el extremo joven (refrescos) del extremo mayor (té)
- El **Eje 2** (15 %) diferencia a los adultos de los otros grupos

6. Resumen estadístico

```
resumen <- data.frame(
  Métrica = c("Chi-cuadrado", "Grados de libertad", "p-valor",
              "Inercia total", "Inercia Eje 1", "Inercia Eje 2",
              "% explicado (ejes 1+2)"),
  Valor   = c(round(chi2, 4), gl,
              format(p_val, scientific = TRUE, digits = 3),
              round(inercia_total, 6),
              paste0(round(pct[1], 2), "%"),
              paste0(round(pct[2], 2), "%"),
              paste0(round(sum(pct[1:2]), 2), "%"))
)
knitr::kable(resumen, align = c("l","r"),
              caption = "Resumen del Análisis de Correspondencias Simples")
```

Tabla 15: Resumen del Análisis de Correspondencias Simples

Métrica	Valor
Chi-cuadrado	95.8875
Grados de libertad	4
p-valor	7.38e-20
Inercia total	0.299648
Inercia Eje 1	85.03 %
Inercia Eje 2	14.97 %
% explicado (ejes 1+2)	100 %

i Conclusión

El p-valor $\approx 7.4e-20$ confirma que **existe asociación significativa** entre edad y bebida. El plano factorial (2 dimensiones) captura el **100 %** de la inercia total, lo que significa que el mapa 2D es una representación casi perfecta de la estructura de asociación en los datos.