

Estadística Descriptiva Multivariada

Jimmy A Corzo S, PhD

jacorzos@unal.edu.co

Giovany Babativa-Márquez, PhD

jgbabativam@unal.edu.co



Análisis de Agrupaciones (Clúster)

¿Qué es el análisis de agrupaciones (clúster)?

Conjunto de técnicas para agrupar objetos con base en la similitud que tienen en un vector de variables $\mathbf{x}' = (x_1, \dots, x_p)$, **sin conocer de antemano** a qué grupo pertenece cada uno.

Un buen agrupamiento cumple dos condiciones simultáneas:

1. **Homogeneidad interna:** los objetos dentro de una misma agrupación (clúster) son lo más similares posible.
2. **Heterogeneidad externa:** las agrupaciones (clústeres) se diferencian claramente entre sí.

A diferencia de la clasificación supervisada, aquí no existe una variable “respuesta” que indique el grupo verdadero: el algoritmo lo construye a partir de la estructura de los datos.

Aplicaciones típicas



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ


- **Segmentación de mercado:** agrupar clientes según hábitos de consumo para diseñar estrategias diferenciadas.
- **Tipologías sociales:** perfiles de ciudadanos según percepciones, actitudes o comportamientos (encuestas).
- **Caracterización territorial:** agrupar países, departamentos o municipios según indicadores socioeconómicos.
- **Reducción de complejidad:** resumir cientos de observaciones en unos pocos perfiles interpretables.
- **Insumo para otras técnicas:** crear una variable de grupo que luego se use en análisis descriptivo o predictivo.

Tipos de análisis de agrupaciones (clúster)




UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ


Métodos Fuzzy



Model Based Clustering




Jerárquicos




Costosos computacionalmente

No Jerárquicos o de partición



Density Based Clustering



En este curso nos concentramos en los dos enfoques clásicos: **jerárquicos** y **de partición (no jerárquicos)**, y en su combinación mediante **HCPC**.

Jerárquicos vs. no jerárquicos

Jerárquicos

Construyen un árbol (dendrograma) agrupando sucesivamente los elementos o grupos más próximos, sin fijar de antemano el número de agrupaciones (clústeres).

Costosos computacionalmente para n grande.

No jerárquicos (partición)

Dividen el conjunto de objetos en un número **prefijado** k de grupos, optimizando algún criterio (p. ej. minimizar la varianza intra-agrupación (intra-clúster)).

Requieren definir k antes de correr el algoritmo.



Etapas de un análisis de agrupaciones (clúster)

1. Definir claramente los **objetivos** del análisis.
2. Seleccionar las **variables** relevantes (evitar redundancia).
3. **Estandarizar** las variables para evitar el efecto de la escala.
4. Elegir una **medida de distancia** o disimilaridad.
5. Elegir el **algoritmo** de agrupación.
6. Obtener la **agrupación** y decidir el número de agrupaciones (clústeres).
7. **Validar** e interpretar los resultados.

Estandarización

Cuando las variables tienen escalas distintas, las de mayor varianza dominan el cálculo de distancias. Se estandariza cada variable como:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \quad j = 1, \dots, p$$

! Important

Esto es indispensable cuando las variables se miden en unidades diferentes (p. ej. ingresos en pesos y años de educación).



Distancia euclídea (la más usada con variables cuantitativas estandarizadas)

$$d_{ij} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

Otras alternativas según el tipo de variable:

- **Manhattan:** $d_{ij} = \sum_{k=1}^p |x_{ik} - x_{jk}|$ – más robusta a atípicos.
- **Distancia χ^2 :** para tablas de frecuencias (la misma del ACS/ACM).
- Existen además otras medidas (p. ej. **Gower**, para mezclas de variables cuantitativas y cualitativas) que no se profundizan en este capítulo.

Cuando las variables activas provienen de un ACP o un ACM, ya se trabaja sobre coordenadas factoriales, ortogonales y en la misma escala: allí la distancia euclídea es la elección natural.



Métodos no jerárquicos: K-medias

El algoritmo de las K -medias

Dado un número de grupos k , el algoritmo busca la partición que **minimiza la suma de cuadrados intra-agrupación (intra-clúster)**:

$$\min \sum_{c=1}^k \sum_{i \in C_c} \|x_i - \bar{x}_c\|^2$$

Dos variantes clásicas:

K-MEANS



Algoritmo K-Means

(Mcqueen, 1967)

Parte de centroides aleatorios, asigna una de las observaciones al cluster del centroide más cercano. Tras esto, recalcula los centroides (media) y asigna la siguiente observación al cluster del centroide más cercano. Y así sucesivamente.

Algoritmo K-Means

(Forgy, 1965)

Partiendo de unos centroides aleatorios, asigna una de las observaciones al cluster del centroide más cercano. Tras haber asignado todas las observaciones a los diferentes cluster, recalcula los centroides de cada agrupación.

COMPUTACIONALMENTE MÁS COSTOSO

¡EN AMBOS ES NECESARIO INDICAR EL NÚMERO DE CLUSTERS K!




Algoritmo de las K -medias: paso a paso





1



- Nº cluster





Algoritmo de las K -medias: paso a paso





Algoritmo de las K -medias: paso a paso





Algoritmo de las K -medias: paso a paso





Algoritmo de las K -medias: paso a paso




Algoritmo de las K -medias: paso a paso




Algoritmo de las K -medias: paso a paso



Algoritmo de las K -medias: resultado final



El centroide se calcula como el vector de medias de los puntos que pertenecen al clúster.



El proceso se repite (reasignar → recalcular centroides) hasta que las asignaciones **no cambian** entre una iteración y la siguiente.




Ejemplo simulado

Seis objetos descritos por dos variables: gasto mensual y años de educación.

```
1 datos <- data.frame(  
2   Individuo = c("A", "B", "C", "D", "E", "F"),  
3   gastos = c(5, 6, 18, 20, 25, 30),  
4   educa = c(5, 6, 14, 15, 20, 19)  
5 )  
6 print(datos)
```

	Individuo	gastos	educa
1	A	5	5
2	B	6	6
3	C	18	14
4	D	20	15
5	E	25	20
6	F	30	19

```
1 ggplot(datos, aes(x = gastos, y = educa, label = Individuo)) +  
2   geom_point(size = 3, color = "steelblue") +  
3   geom_text(vjust = -1) +  
4   labs(x = "Gastos", y = "Años de educación") +  
5   theme_bw()
```



A simple vista se intuyen (al menos) dos grupos: {A, B} y {C, D, E, F}, y posiblemente un tercero {E, F} dentro de este último.

Estandarización de las variables

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$



```
1 (datos_z <- datos |>
2   mutate(gastoz = (gastos - mean(gastos)) / sd(gastos),
3   educaz = (educa - mean(educa)) / sd(educa)))
```

	Individuo	gastos	educa	gastoz	educaz
1	A	5	5	-1.22438718	-1.2822130
2	B	6	6	-1.12511254	-1.1252073
3	C	18	14	0.06618309	0.1308381
4	D	20	15	0.26473236	0.2878437
5	E	25	20	0.76110554	1.0728721
6	F	30	19	1.25747872	0.9158664

Matriz de distancias



```
1 mat_z <- datos_z[, c("gastoz", "educaz")]
2 rownames(mat_z) <- datos_z$Individuo
3 (distancias <- dist(mat_z))
```

	A	B	C	D	E
B	0.1857585				
C	1.9137097	1.7311370			
D	2.1639212	1.9820147	0.2531256		
E	3.0803583	2.8964412	1.1706175	0.9287927	
F	3.3152996	3.1373114	1.4266937	1.1747161	0.5206122


Los objetos A-B, C-D y E-F son los pares más próximos: son los primeros candidatos a fusionarse en cualquier algoritmo de agrupación.

Aplicación de K -medias ($k = 2$)



```
1 set.seed(123)
2 km <- kmeans(datos_z[, c("gastoz", "educaz")], centers = 2)
3 datos_z$cluster <- as.factor(km$cluster)
4 km$cluster
```

```
[1] 1 1 2 2 2 2
```



Métodos para elegir k

El número de agrupaciones (clústeres) k debe fijarse **antes** de correr K-medias. Existen varios criterios para ayudar a elegirlo:



[Codo](#) [Silueta](#) [Hartigan](#) [Calinski-Harabasz](#)

Método del codo (elbow)

Grafica la suma de cuadrados intra-agrupación (intra-clúster) (WSS) contra k :

$$WSS(k) = \sum_{c=1}^k \sum_{i \in C_c} \|x_i - \bar{x}_c\|^2$$

WSS siempre **disminuye** al aumentar k . Se busca el punto donde la curva deja de descender rápidamente — el “codo” — porque agregar más grupos aporta poca reducción adicional de varianza.

! Important

El codo es una regla visual (subjetiva); silueta, Hartigan y Calinski-Harabasz dan un valor numérico comparable entre distintos k . Se recomienda usar **varios criterios** junto con el criterio del analista.

¿Cómo elegir k ?




Método del codo

Silueta

Hartigan

Calinski-Harabasz

```
1 fviz_nbclust(datos_z[, c("gastoz", "educaz")], kmeans,  
2               method = "wss", k.max = 5) +  
3   labs(title = "Suma de cuadrados intra-agrupación (intra-clúster) (WSS)")
```





Métodos jerárquicos


La idea de jerarquía

Los métodos jerárquicos construyen agrupaciones **anidadas**, igual que una clasificación taxonómica: cada nivel agrupa a los elementos del nivel anterior.



UNIVERSIDAD
NACIONAL
DE COLOMBIA

SEDE BOGOTÁ



Algoritmo de aglomeración jerárquica



1. Comenzar con tantos grupos como objetos (n grupos). Las distancias entre grupos son las distancias entre los elementos originales.
2. Fusionar los **dos grupos más próximos** según la matriz de distancias.
3. Sustituir esos dos grupos por uno nuevo que los representa, y **recalcular** las distancias de este nuevo grupo con los demás.
4. Repetir (2) y (3) hasta que todos los elementos queden en un único grupo.

El resultado es un **dendrograma**: un árbol que resume el orden y la “altura” (distancia) a la que se produjo cada fusión.

Criterios de enlace (linkage)

La forma de “recalcular” la distancia entre grupos define el método:

Método	Distancia entre grupos A y B	Característica
Simple (single)	$\min_{i \in A, j \in B} d_{ij}$	Sensible a efecto “cadena”
Completo (complete)	$\max_{i \in A, j \in B} d_{ij}$	Grupos compactos, sensible a atípicos
Promedio (average)	$\frac{1}{ A B } \sum_{i \in A, j \in B} d_{ij}$	Compromiso entre los anteriores
Ward	Mínimo incremento en la inercia intra-agrupación (intra-clúster) al fusionar	El más usado en la práctica




Ejemplo simulado: dendrograma




```
1 hc_complete <- hclust(distancias, method = "complete")
2
3 plot(hc_complete, labels = datos$Individuo,
4      main = "Agrupación jerárquica (clúster) (enlace completo)",
5      sub = "", xlab = "", ylab = "Distancia")
6 rect.hclust(hc_complete, k = 2, border = "red")
```

Agrupación jerárquica (clúster) (enlace completo)



Simple Completo Promedio Ward

```
1 plot(hclust(distancias, method = "single"), labels = datos$Individuo,  
2      main = "Enlace simple", sub = "", xlab = "", ylab = "Distancia")
```



En este ejemplo, **los cuatro criterios** coinciden en la partición en dos grupos: {A, B} y {C, D, E, F}, el mismo resultado que arrojó K-medias. En datos reales esto no siempre ocurre: la elección del método sí puede cambiar la agrupación.

¿Cuántos grupos retener?



- **Regla visual:** cortar el dendrograma donde la distancia vertical entre fusiones consecutivas sea **grande** (un “salto” evidente).
- **Criterio de inercia:** identificar el número de grupos k a partir del cual la pérdida relativa de inercia inter-agrupación (inter-clúster) al pasar de k a $k - 1$ grupos es grande, es decir, al fusionar esos dos grupos quedan siendo menos diferentes entre sí. Se retiene el k inmediatamente anterior a esa pérdida grande.
- Ambos criterios coinciden con la lógica que usa `HCPC()` para sugerir automáticamente un número de grupos.



HCPC: Clasificación jerárquica sobre componentes principales

La idea del HCPC

HCPC() (*Hierarchical Clustering on Principal Components*) combina lo mejor de los dos mundos vistos hasta ahora, en tres etapas:



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

1. **Reducción de dimensión:** se parte de las coordenadas factoriales de un ACP, ACM o ACS (en vez de las variables originales).
2. **Clasificación jerárquica** (Ward) sobre esas coordenadas, para construir el dendrograma y sugerir el número de agrupaciones (clústeres).
3. **Consolidación** de la partición con un algoritmo de K -medias, partiendo de los centros de gravedad obtenidos en el paso jerárquico, utilizando como valor de K el número de agrupaciones (clústeres) que acaba de generar la clasificación jerárquica en el paso anterior.

¿Por qué trabajar sobre componentes?

- Las coordenadas factoriales son **ortogonales**: se elimina la redundancia (correlación) entre variables originales.
- Al retener solo los primeros ejes se **filtra ruido** y se reduce el costo computacional.
- Permite unificar el flujo de trabajo: el **mismo objeto** (`PCA()`, `MCA()` o `CA()`) alimenta tanto el mapa factorial como la clasificación.
- `HCPC()` produce, además del dendrograma, una **caracterización automática** de cada agrupación (clúster): qué variables (o modalidades) lo tipifican.





Estudio de caso 1: perfiles de calidad de vida departamental

```
1 library(pacman)
2 p_load(tidyverse, FactoMineR, factoextra, gt)
```


Retomamos los 33 departamentos colombianos y sus 15 indicadores de calidad de vida (ECV-DANE 2022) usados en el ACP.

```
1 url <- "https://github.com/jgbabativam/Curso_Multivariado/raw/main/Datos/"
2
3 ecv <- read.csv(paste0(url, "ecv_departamentos_2022.csv"), header = TRUE) |>
4   column_to_rownames("departamento") |>
5   rename(inv_hacinamiento = sin_hacinamiento,
6          inv_ipm = sin_ipm, leen_adultos = lit_adultos)
```

Paso 1: ACP (recordatorio)



```
1 pca_ecv <- PCA(ecv, graph = FALSE, scale.unit = TRUE, ncp = 5)
1 fviz_eig(pca_ecv, addlabels = TRUE, ncp = 5) +
2   labs(title = "Varianza explicada - Calidad de vida ECV 2022",
3     x = "Componente", y = "% varianza explicada") + theme_bw()
```



Paso 2: HCPC — dendrograma




```
1 res.clus.ecv <- HCPC(pca_ecv, graph = FALSE)
2 table(res.clus.ecv$data.clust$clust)
```

```
1  2  3
4 13 16
```

```
1 fviz_dend(res.clus.ecv, cex = 0.6, palette = "jco",
2           rect = TRUE, rect_fill = TRUE, horiz = TRUE,
3           rect_border = "jco", labels_track_height = 0.8,
4           main = "Dendrograma — Departamentos según calidad de vida")
```


Dendrograma — Departamentos según calidad de vida



Paso 3: Plano factorial por agrupación (clúster)



```
1 fviz_cluster(res.clus.ecv, repel = TRUE,  
2               show.clust.cent = TRUE, palette = "jco",  
3               ggtheme = theme_minimal(),  
4               main = "Agrupación de departamentos (clúster) — Calidad de vida ECV 2022")
```



Caracterización de las agrupaciones (clústeres)

leen_adultos: % de adultos que saben leer y escribir. inv_ipm: inverso del IPM (100 – IPM).
inv_hacinamiento: inverso del % de hogares en hacinamiento (100 – % hacinamiento).



```
1 desc_ecv <- map_dfr(names(res.clus.ecv$desc.var$quanti), function(k) {  
2   as.data.frame(res.clus.ecv$desc.var$quanti[[k]]) |>  
3   rownames_to_column("variable") |>  
4   mutate(cluster = k) |>  
5   select(cluster, variable, `Mean in category`, `Overall mean`, v.test) |>  
6   slice_max(order_by = abs(v.test), n = 4)  
7 })
```

Variable	Media en agrupación (clúster)	Media global	v.test
1			
energia	78.0	94.7	-5.1
leen_adultos	81.2	92.1	-4.5
inv_ipm	47.4	77.7	-4.4
afiliacion_salud	74.4	86.7	-4.4
2			
computador	14.3	24.3	-3.2
internet	20.9	33.6	-3.1
gas_natural	8.9	22.2	-3.0
educ_superior	8.6	13.1	-3.0
3			
internet	50.2	33.6	4.9
computador	37.1	24.3	4.9
paredes_adec	88.1	74.1	4.8
piso_adec	84.7	69.8	4.8

- **Agrupación 1 (Clúster 1)** (4 dptos: Amazonas, Vaupés, Guainía, Vichada): valores **muy por debajo** de la media nacional en energía, alfabetización de adultos (*leen_adultos*), el indicador invertido de pobreza multidimensional (*inv_ipm*) y afiliación en salud. Es el grupo con las condiciones de vida más precarias — la Amazonía y la Orinoquía profundas.
- **Agrupación 2 (Clúster 2)** (13 dptos: Caribe, Pacífico, Arauca, Caquetá, Putumayo...): valores **por debajo** de la media en acceso a computador, internet, gas natural y educación superior — departamentos históricamente afectados por el conflicto y con menor cobertura de servicios.
- **Agrupación 3 (Clúster 3)** (16 dptos: Bogotá, Antioquia, Valle, eje cafetero, Santanderes...): valores **por encima** de la media en acceso a internet y computador, y en calidad de vivienda (paredes y piso adecuados) — la región Andina y las principales áreas metropolitanas.

Objetos “parangón” de cada agrupación (clúster)

Son los departamentos **más representativos** (más cercanos al centro de su agrupación (clúster)):



```
1 map_dfr(names(res.clus.ecv$desc.ind$para), function(k) {  
2   tibble(cluster = k, departamento = names(res.clus.ecv$desc.ind$para[[k]]),  
3     distancia = round(res.clus.ecv$desc.ind$para[[k]], 3))  
4 }) |> gt(groupname_col = "cluster") |>  
5   tab_options(table.font.size = px(18), data_row.padding = px(3))
```

departamento	distancia
1	
Vaupés	0.107
Guainía	0.606
Vichada	1.431
Amazonas	1.949
2	
Sucre	0.190
Nariño	0.321
Putumayo	0.340
Córdoba	0.476
Magdalena	0.503



Estudio de caso 2: retomando el ACM — confianza institucional

Recordando el ACM: LAPOP Colombia 2021

Retomamos el ejemplo de confianza institucional (b2, b3, b4, b6, b32, b47a; escalas recodificadas Baja/Media/Alta) con el género como variable suplementaria.



```
1 lapop_raw <- read_dta(paste0(url, "COL_2021_LAPOP.dta"))
2
3 recode_trust <- function(x) {
4   xn <- suppressWarnings(as.numeric(x))
5   dplyr::case_when(
6     xn %in% 1:3 ~ "Baja",
7     xn == 4 ~ "Media",
8     xn %in% 5:7 ~ "Alta",
9     TRUE ~ NA_character_
10  )
11 }
12
13 lapop_acm <- lapop_raw |>
14   transmute(
15     Respeto = recode_trust(b2), Derechos = recode_trust(b3),
16     Orgullo = recode_trust(b4), Apoyo = recode_trust(b6),
17     GobLocal = recode_trust(b32), Elecciones = recode_trust(b47a),
18     Genero = dplyr::case_when(as.numeric(q1tb) == 1 ~ "Hombre",
19                               as.numeric(q1tb) == 2 ~ "Mujer",
20                               TRUE ~ NA_character_)
21   ) |> drop_na() |> mutate(across(everything(), factor))
22
23 acm_lapop <- MCA(lapop_acm,
24                  quali.sup = which(names(lapop_acm) == "Genero"),
25                  graph = FALSE)
```


HCPC sobre las coordenadas del ACM



```
1 res.clus.lapop <- HCPC(acm_lapop, graph = FALSE)
2 table(res.clus.lapop$data.clust$clust)
```

```
1 2 3 4
487 126 368 385
```


Dendrograma — Confianza institucional LAPOP 2021



Plano de objetos coloreado por agrupación (clúster)



```
1 fviz_cluster(res.clus.lapop, geom = "point", alpha = 0.4,  
2 palette = "jco", ggtheme = theme_minimal(),  
3 main = "Encuestados LAPOP 2021 según legitimidad política")
```



Caracterización cualitativa de las agrupaciones (clústeres)



```
1 desc_lapop <- map_dfr(names(res.clus.lapop$desc.var$category), function(k) {  
2   as.data.frame(res.clus.lapop$desc.var$category[[k]]) |>  
3   rownames_to_column("modalidad") |>  
4   mutate(cluster = k) |>  
5   select(cluster, modalidad, `Mod/Cla`, `Cla/Mod`, Global, v.test) |>  
6   slice_max(order_by = v.test, n = 4)  
7 })
```

Modalidad	% Mod/Cla	% Cla/Mod	% global	v.test
1				
Apoyo=Apoyo_Baja	86.0	75.0	40.9	26.1
Orgullo=Orgullo_Baja	93.4	68.0	49.0	26.1
Derechos=Derechos_Baja	92.8	54.3	60.9	19.3
Elecciones=Elecciones_Baja	92.2	53.7	61.2	18.7
2				
Respeto=Respeto_Media	100.0	95.5	9.7	28.0
Derechos=Derechos_Baja	77.8	11.8	60.9	4.2
GobLocal=GobLocal_Baja	67.5	12.0	51.8	3.7
Elecciones=Elecciones_Baja	75.4	11.4	61.2	3.5
3				
Orgullo=Orgullo_Media	45.1	78.7	15.4	17.3
Apoyo=Apoyo_Media	44.8	75.7	16.0	16.7
Derechos=Derechos_Media	41.6	68.0	16.5	14.3
Respeto=Respeto_Alta	90.2	36.4	66.7	12.0
4				



- **Agrupación 1 (Clúster 1)** (n=487, 36%): domina la modalidad “**Baja**” en las seis variables — ciudadanos con **desafección generalizada** hacia el sistema político.
- **Agrupación 2 (Clúster 2)** (n=126, 9%): grupo pequeño y atípico, tipificado casi exclusivamente por “**Respeto Media**” (concentra el 100% de esa modalidad); en el resto de variables se inclina hacia valores bajos. Es el tipo de perfil “particular” que un análisis exploratorio univariado difícilmente detectaría.
- **Agrupación 3 (Clúster 3)** (n=368, 27%): predominan las modalidades “**Media**” — ciudadanos **ambivalentes**, ni claramente críticos ni claramente leales al sistema.
- **Agrupación 4 (Clúster 4)** (n=385, 28%): domina la modalidad “**Alta**” en todas las variables — ciudadanos con **alta legitimidad percibida** del sistema político. Esta agrupación (clúster) tiene una proporción de **mujeres significativamente mayor** a la esperada (χ^2 , p = 0.022), asociación visible gracias a **Genero** como variable suplementaria.

De la teoría a la práctica

El mismo flujo de trabajo: reducir dimensión, clasificar jerárquicamente y consolidar con K-medias; funciona igual sobre coordenadas de un **ACP** (variables cuantitativas) que de un **ACM** (variables cualitativas). Lo único que cambia es el objeto que se pasa a **HCPC()**.





Laboratorio



```
1 library(pacman)
2 p_load(tidyverse, FactoMineR, factoextra, cluster, haven, janitor)
3
4 url <- "https://github.com/jgbabatvam/Curso_Multivariado/raw/main/Datos/"
```

Cada grupo trabajará con una **semilla distinta**, un conjunto de variables cuantitativas para K-medias/jerárquico y un subconjunto de ítems cualitativos para el ACM + HCPC.

Grupo	Semilla	Datos cuantitativos	ACM + HCPC: ítems p20 (Muestra_CC.csv)
1	1357	SUEsolo2012.csv (universidades públicas)	a, b, c, d, e
2	2468	r14_Sci_Qs_Webometrics.csv (universidades LatAm)	f, g, h, i, j
3	3579	ecv_departamentos_2022.csv (otro subconjunto de indicadores)	c, d, e, f, k
4	9753	IPM2025.sav (pobreza multidimensional)	a, g, h, i, j, k
5	6813	ARWU_100_top.csv (ranking mundial de universidades)	b, e, g, i, k

Laboratorio — K-medias (1/3)

Con el conjunto de datos cuantitativos asignado a su grupo:

1. Seleccione al menos **4 variables cuantitativas** relevantes y elimine observaciones con datos faltantes.
2. **Estandarice** las variables y justifique por qué es necesario en este caso.
3. Use `fviz_nbclust()` (WSS y silueta) para proponer un número de agrupaciones (clústeres) k .
4. Aplique `kmeans()` con el k elegido y su semilla asignada (`set.seed()`).
5. Visualice la partición con `fviz_cluster()` y calcule la **silueta promedio** (`silhouette()`, `fviz_silhouette()`). ¿La calidad de la partición es adecuada?

Laboratorio — Jerárquico (2/3)



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

6. Con la misma matriz estandarizada, construya la **matriz de distancias** (`dist()`) y aplique `hclust()` con al menos **dos criterios de enlace** distintos.
7. Grafique ambos dendrogramas. ¿Los cortes en el mismo número de grupos coinciden con la partición de K-medias?
8. Aplique un **ACP** sobre las mismas variables y luego `HCPC()` sobre el resultado. Compare el número de agrupaciones (clústeres) sugerido automáticamente con el que usted eligió en el punto 3.
9. Use `res.clus$desc.var$quanti` para **caracterizar** cada agrupación (clúster): ¿qué variables lo definen y en qué sentido (por encima o por debajo de la media)?
10. Nombre cada agrupación (clúster) con una etiqueta descriptiva y redacte un párrafo de interpretación.

Laboratorio — ACM + HCPC (3/3)

Con los ítems de justificación para desobedecer la ley asignados a su grupo:

1. Aplique el **ACM** (`MCA()`) sobre los ítems asignados.
2. Aplique `HCPC()` sobre el resultado del ACM. ¿Cuántas agrupaciones (clústeres) sugiere automáticamente?
3. Grafique el dendrograma y el plano de objetos coloreado por agrupación (clúster).
4. Use `res.clus$desc.var$category` para identificar las modalidades que **tipifican** cada agrupación (clúster).
5. Agregue **ciudad** o **nivel educativo** (`Muestra_CC.csv`) como variable suplementaria en el ACM antes de correr `HCPC()`. ¿Alguna de estas variables se asocia significativamente con alguna agrupación (clúster)?
6. Elabore una **caracterización final**: nombre cada agrupación (clúster) según el perfil de justificaciones que lo tipifica.



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

GRACIAS!

Citación y derechos de autor

Este material ha sido creado por Jimmy Corzo y [Giovany Babativa-Márquez](#) y es de libre distribución bajo la licencia [Creative Commons Attribution-ShareAlike 4.0](#).

Cualquier copia parcial o total de este material, debe citar la fuente como:

Corzo J., & Babativa-Márquez, J.G. *Diapositivas del curso de estadística descriptiva multivariada*. URL:
https://jgbabativam.github.io/Curso_Multivariado/