

Estadística Descriptiva Multivariada

Jimmy A Corzo S, PhD Giovany Babativa-Márquez, PhD

jacorzos@unal.edu.co

jgbabativam@unal.edu.co



Análisis de Correspondencias

Análisis de Correspondencias Simples Análisis de Correspondencias Múltiples

- | | |
|---|---|
| 1. Descripción del método | 9. Del ACS al ACM |
| 2. Tablas de contingencia y perfiles | 10. Tabla disyuntiva y Tabla de Burt |
| 3. Inercia y distancia χ^2 | 11. Inercia de modalidades |
| 4. Obtención de los factores | 12. Guías para la interpretación |
| 5. Guías para la interpretación | 13. Ej. 1: Justificaciones desobediencia (ECC) |
| 6. Ej. 1: Sentimientos ante normas (ECC) | 14. Ej. 2: Confianza en instituciones — LAPOP Colombia 2021 |
| 7. Ej. 2: Confianza en la justicia en 38 países | 15. Laboratorio |
| 8. Ej. 3: Candidatos Bogotá 2023 | |



Análisis de correspondencias simples

¿Qué es el ACS?

El ACP requiere variables cuantitativas. Cuando los datos provienen de encuestas con respuestas categóricas, las escalas son **códigos** asignados a modalidades: no hay operaciones aritméticas con sentido entre ellas.

El Análisis de Correspondencias Simples (ACS):

- Es una extensión del ACP para identificar relaciones entre **dos variables cualitativas**. *Cualitativas*
- Visualiza tablas de frecuencias o **tablas de contingencia** en un plano de pocas dimensiones.
- Puede interpretarse como un ACP para variables cualitativas.
- Identifica asociaciones entre las **modalidades de respuesta** de ambas variables.

Note

Cuando se trata de **más de dos** variables cualitativas, el método se generaliza al **Análisis de Correspondencias Múltiples (ACM)**, tratado en la segunda parte de esta presentación.

Escalas de variables cualitativas

- **Nominal:** códigos que clasifican objetos sin orden. *Ejemplos:* sexo, ciudad, estado civil, universidad, país.
- **Ordinal o categórica:** categorías que indican **jerarquía u orden**. *Ejemplos:* estrato socioeconómico, nivel educativo, posición en ranking.
- **Likert:** escala ordinal para grados de aprobación o acuerdo. *Modalidades típicas:* Totalmente en desacuerdo · En desacuerdo · Indiferente · De acuerdo · Totalmente de acuerdo.
- **Hedonista:** escala ordinal de **niveles de preferencia o agrado**. *Modalidades:* Me desagrada mucho · Me desagrada · Ni me agrada ni desagrada · Me agrada · Me agrada mucho.

Las opciones de respuesta se denominan **modalidades**. Las variables generadas por estas codificaciones son **variables cualitativas**.




Tablas de contingencia

Estructura de la tabla de contingencia

Sea X la variable fila con I modalidades y Y la variable columna con J modalidades. La tabla de contingencia es:

$$G = \{n_{ij}\}, \quad i = 1, \dots, I, \quad j = 1, \dots, J$$

donde n_{ij} es el número de respuestas simultáneas a la modalidad i de X y la modalidad j de Y .


$$G = \left\{ \begin{matrix} n_{11} \\ n_{22} \\ \vdots \\ n_{ij} \end{matrix} \right\}$$

Estructura de la tabla de contingencia

	1	2	...	j	...	J	
1	n_{11}	n_{12}	...	n_{1j}	...	n_{1J}	$n_{1.}$
	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{iJ}	$n_{i.}$
	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
I	n_{I1}	n_{I2}	...	n_{Ij}	...	n_{IJ}	$n_{I.}$
	$n_{.1}$	$n_{.2}$	...	$n_{.j}$	...	$n_{.J}$	n

Las **frecuencias marginales** son: $n_{i.} = \sum_{j=1}^J n_{ij}$ (fila) y $n_{.j} = \sum_{i=1}^I n_{ij}$ (columna).

Frecuencias por filas y columnas

De frecuencias a perfiles



Las frecuencias absolutas n_{ij} dependen del total n y no permiten comparar directamente. Las frecuencias relativas $f_{ij} = n_{ij}/n$ tampoco eliminan el efecto de las marginales.

Frecuencias relativas

La solución son los **perfiles** (frecuencias condicionales):

Perfiles fila: $\frac{f_{ij}}{f_{i.}} = \frac{n_{ij}}{n_{i.}}$

Perfiles columna: $\frac{f_{ij}}{f_{.j}} = \frac{n_{ij}}{n_{.j}}$

donde $f_{i.} = n_{i.}/n$ y $f_{.j} = n_{.j}/n$ son las frecuencias marginales relativas.

$G_I = (f_{.1}, \dots, f_{.J})$ es el **centroide de filas** (perfil promedio de filas). $G_J = (f_{1.}, \dots, f_{I.})$ es el **centroide de columnas**.

Inercia y distancia χ^2



Si X e Y son **independientes**, se espera $f_{ij} = f_{i.} f_{.j}$. Se definen las **frecuencias esperadas**:

$$\hat{e}_{ij} = f_{i.} f_{.j}$$

Frecuencias
esperadas

Las **distancias estandarizadas** entre observado y esperado son:

$$z_{ij} = \frac{f_{ij} - \hat{e}_{ij}}{\sqrt{\hat{e}_{ij}}}$$

Observado - Esperado.

La estadística χ^2 y la **inercia total** son:

$$\chi^2 = n \sum_{i=1}^I \sum_{j=1}^J z_{ij}^2 \quad \Rightarrow \quad T = \frac{\chi^2}{n} = \sum_{i=1}^I \sum_{j=1}^J z_{ij}^2$$

Distancia estandarizada para todo i, j *Inercia, suavizarnos para tamaño n .*

! Important

La **inercia** T elimina el efecto del tamaño muestral. Es la varianza total que el ACS descompone en factores.



Obtención de los factores

factores

Diferencias entre ACP y ACS

- **ACP:** En las tablas de datos del ACP las filas representan objetos y las columnas son las variables, de manera que el análisis por filas es un análisis de similitudes entre objetos, el análisis por columnas es un análisis de correlación entre variables.
- **ACS:** Las filas y columnas representan las modalidades de dos variables cualitativas, y por tanto la interpretación de los dos análisis es la misma. Asociación entre modalidades de la variable que está en las filas (columnas) y el análisis simultáneo de filas y columnas es para identificar el grado de asociación entre modalidades de las dos variables.

Las **coordenadas** de filas y columnas sobre el α -ésimo factor son promedios ponderados de las distancias estandarizadas:

$$r_{i\alpha} = \sum_{j=1}^J z_{ij} u_{j\alpha} = \sum_{j=1}^J \frac{f_{ij} - \hat{e}_{ij}}{\sqrt{\hat{e}_{ij}}} u_{j\alpha} \quad (\text{filas})$$

Distancias ponderadas para ese α .

$$c_{j\alpha} = \sum_{i=1}^I z_{ij} v_{i\alpha} = \sum_{i=1}^I \frac{f_{ij} - \hat{e}_{ij}}{\sqrt{\hat{e}_{ij}}} v_{i\alpha} \quad (\text{columnas})$$

Promedios en relación para α .

Equivalencia con perfiles: un enfoque que produce los mismos resultados consiste en proyectar directamente los perfiles fila y columna. Las coordenadas de las filas son:

$$r_{\alpha i} = \frac{1}{f_{i.}} \sum_{j=1}^J \frac{f_{ij}}{f_{.j}} u_{j\alpha}$$

Construcción con frecuencias relativas

Ecuaciones de transición

Los vectores propios de las matrices de filas y columnas están relacionados por:

$$v_{\alpha} = \frac{1}{\sqrt{\lambda_{\alpha}}} F D_J^{-1} u_{\alpha} \qquad u_{\alpha} = \frac{1}{\sqrt{\lambda_{\alpha}}} F' D_I^{-1} v_{\alpha}$$

donde $F = \{f_{ij}\}$ es la matriz de frecuencias relativas, $D_I = \text{diag}(f_{i.})$ y $D_J = \text{diag}(f_{.j})$.

Las ecuaciones de transición permiten, a partir de las coordenadas de un espacio, calcular las del otro. Es la base de la **representación simultánea** de filas y columnas en el mismo plano.

Filas y columnas suplementarias: para filas o columnas que no participan en el cálculo, sus coordenadas se obtienen proyectando sus perfiles sobre los factores ya calculados.



Interpretación del ACS

Tres herramientas de interpretación

1. **Coordenadas** ($r_{i\alpha}, c_{j\alpha}$): posición de la modalidad sobre el factor.
2. **Contribuciones**: aporte de la modalidad a la inercia del factor:

$$C_{\alpha}(i) = \frac{f_i \cdot r_{\alpha i}^2}{\lambda_{\alpha}} \quad C_{\alpha}(j) = \frac{f_j \cdot c_{\alpha j}^2}{\lambda_{\alpha}}$$

3. **Cosenos cuadrados**: capacidad del factor para representar la modalidad:

$$\cos_{\alpha}^2(i) = \frac{r_{\alpha i}^2}{d^2(i, G_I)} \quad \cos_{\alpha}^2(j) = \frac{c_{\alpha j}^2}{d^2(j, G_J)}$$

Note

Modalidades con **coordenada alta + contribución alta + $\cos^2$ alto** tipifican el factor y pueden usarse como indicadores de las propiedades que define ese factor.

Reglas de interpretación de las coordenadas

- **Puntos fila, columna o mixtos cercanos entre sí** → los encuestados que contestaron una modalidad también contestaron la otra; sus distribuciones son similares.
- **Puntos cercanos al centro del plano** → modalidades con frecuencias **altas** de respuesta; representan la opinión de la mayoría (punto promedio o modal).
- **Puntos lejanos del origen** → modalidades con frecuencias **bajas** de respuesta; son las que más distinguen a los individuos.
- **Puntos en extremos opuestos del plano** → baja frecuencia de respuesta y distribuciones opuestas; indican opiniones contrapuestas.

Warning

El ACS **aleja del origen** las modalidades poco frecuentes, identificando así las características que más distinguen a los objetos.



Ejemplo 1: Sentimientos ante normas — ECC



La **Encuesta de Cultura Ciudadana (ECC)** fue realizada por Corporación Visionarios en varias ciudades latinoamericanas. Incluye preguntas sobre sentimientos hacia normas, facilidad para cumplir la ley, celebración de acuerdos, confianza, seguridad y pluralismo.

Dos preguntas permiten explorar si quienes tienen sentimientos positivos hacia las normas también les queda más fácil cumplirlas:

P16. *De modo general, las palabras regla o norma despiertan en Usted un sentimiento:*

1. Muy negativo | 2. Negativo | 3. Indiferente | 4. Positivo | 5. Muy positivo |

P17b. *Le queda fácil actuar conforme a la ley:*

1. Nunca | 2. Casi nunca | 3. Casi siempre | 4. Siempre |

Carga de los datos



```
1 library(pacman)
2 p_load(tidyverse, FactoMineR, factoextra, gt, janitor, corrplot)
3
4 url <- "https://github.com/jgbabativam/Curso_Multivariado/raw/main/Datos/"
5 CCLatin <- read_csv2(paste0(url, "Muestra_CC.csv"), sep = ";")
6
7 t16x17 <- table(CCLatin$p16, CCLatin$p17_b)
```

Tabla de contingencia: sentimientos ante normas x facilidad para cumplir la ley

P16 \ P17b	p17b_FACL=1_n	p17b_FACL=2_cn	p17b_FACL=3_cs	p17b_FACL=4_s
p16_PNOR=1_muyneg	1	0	0	7
p16_PNOR=2_neg	3	12	19	21
p16_PNOR=3_indif	0	3	8	4
p16_PNOR=4_posi	27	113	523	547
p16_PNOR=5_muypos	5	17	84	140

```
1 perfilesF <- as.data.frame.matrix(t16x17)
2 perf_fil <- cbind(perfilesF, TotFil = rowSums(t16x17))
3 perfilas <- round(perf_fil / perf_fil$TotFil, 3)
```

Perfiles fila: distribución de facilidad para cumplir la ley según sentimiento ante normas

Sentimiento (P16)	p17b_FACL=1_n	p17b_FACL=2_cn	p17b_FACL=3_cs	p17b_FACL=4_s	TotFil
p16_PNOR=1_muyneg	0.125	0.000	0.000	0.875	1
p16_PNOR=2_neg	0.055	0.218	0.345	0.382	1
p16_PNOR=3_indif	0.000	0.200	0.533	0.267	1
p16_PNOR=4_posi	0.022	0.093	0.432	0.452	1
p16_PNOR=5_muypos	0.020	0.069	0.341	0.569	1

Note

Los perfiles fila eliminan el efecto del total de encuestados y permiten comparar directamente las distribuciones entre modalidades. Observe que el sentimiento “Indiferente” tiene la mayor proporción en “Casi siempre” + “Siempre”.

```
1 perColum <- round(sweep(perfilesF, 2, colSums(perfilesF), "/"), 3)
```

Perfiles columna para el sentimiento ante reglas o normas vs. facilidad para obedecer la ley

Sentimiento (P16)	p17b_FACL=1_n	p17b_FACL=2_cn	p17b_FACL=3_cs	p17b_FACL=4_s
p16_PNOR=1_muyneg	0.028	0.000	0.000	0.010
p16_PNOR=2_neg	0.083	0.083	0.030	0.029
p16_PNOR=3_indif	0.000	0.021	0.013	0.006
p16_PNOR=4_posi	0.750	0.779	0.825	0.761
p16_PNOR=5_muypos	0.139	0.117	0.132	0.195

Note

Se elimina el efecto del total de encuestados. Hay una fuerte similitud entre las distribuciones según la facilidad para actuar conforme a la ley. Lo paradójico es que cualquiera sea el grado de facilidad para actuar conforme a la ley, en todos los casos domina el sentimiento positivo y en menor grado muy positivo.

ACS — Tabla de contingencia ECC



```
1 acs_p16x17 <- CA(as.data.frame.matrix(t16x17), graph = FALSE)
```

```
1 eig_acs <- get_eigenvalue(acs_p16x17)
2 round(eig_acs, 3)
```


	eigenvalue	variance.percent	cumulative.variance.percent
Dim.1	0.016	62.569	62.569
Dim.2	0.008	32.668	95.237
Dim.3	0.001	4.763	100.000

Análisis de las filas — Factores 1 y 2



Modalidad	Coordenadas		Contribuciones (%)		Cos ²	
	F1	F2	F1	F2	F1	F2
p16_PNOR=1_muyneg	-0.94	0.60	28.84	22.46	0.68	0.28
p16_PNOR=2_neg	0.25	0.41	13.91	72.25	0.27	0.73
p16_PNOR=3_indif	0.50	-0.01	15.21	0.01	0.94	0.00
p16_PNOR=4_posi	0.03	-0.02	3.96	5.24	0.52	0.36
p16_PNOR=5_muypos	-0.19	0.01	38.09	0.05	0.92	0.00

Cos² por factor



Note

Factor 1 queda tipificado por **muy positivo** (contr. 38.09%, $\cos^2=0.92$) —pese a tener la menor coordenada en valor absoluto (-0.19)— y por **indiferente** (coord. 0.50, $\cos^2=0.94$, contr. 15.21%). Las modalidades **muy neg** y **neg** definen el **Factor 2**, contribuyendo conjuntamente el 94.6% de su inercia. **Lectura del Factor 1:** coordenadas extremas negativas → sentimientos muy negativos; pequeñas negativas → sentimientos muy positivos; positivas (~ 0.5) → indiferencia ante las normas.


Plano factorial — Análisis por filas



UNIVERSIDAD
NACIONAL
DE COLOMBIA

SEDE BOGOTÁ

```
1 fviz_ca_row(acs_p16x17, repel = TRUE, col.row = "cos2",  
2 gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
3 title = "Análisis por filas - Sentimientos ante palabras como regla o norma") + theme_bw()
```




Indicadores de columnas — Facilidad para actuar conforme a la ley



Modalidad	Coordenadas		Contribuciones (%)		Cos ²	
	F1	F2	F1	F2	F1	F2
p17b_FACL=1_n	-0.09	0.37	1.15	38.85	0.04	0.79
p17b_FACL=2_cn	0.24	0.18	33.81	35.04	0.63	0.34
p17b_FACL=3_cs	0.09	-0.07	20.79	25.62	0.59	0.38
p17b_FACL=4_s	-0.12	0.01	44.25	0.49	0.98	0.01

Cos² por factor




Note


Factor 1 está mejor tipificado por **siempre** (p17b_FACL=4_s): mayor contribución (44.25%) y mejor representada sobre este factor ($\cos^2=0.98$), con coordenada negativa (-0.12). La modalidad **casi nunca** tiene la mayor coordenada positiva (0.24) y alta contribución (33.81%). **Factor 2** es un indicador de poca facilidad para cumplir la ley: **nunca** (p17b_FACL=1_n) tiene la mayor coordenada (0.37), la mayor contribución (38.85%) y el mejor $\cos^2$ en F2 (0.79), situándose lejos del origen.



```
1 fviz_ca_col(acs_p16x17, repel = TRUE, col.col = "cos2",  
2 gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
3 title = "Análisis por columnas - Facilidad para actuar conforme a la ley") + theme_bw()
```



```
1 fviz_ca_biplot(acs_p16x17, repel = TRUE, col.row = "#0077b6", col.col = "#C0392B",  
2 title = "Asociación entre sentimientos y facilidad para cumplir la ley") + theme_bw()
```



Note

Centro del plano: *siempre y casi siempre* (azul) se ubican junto a *indiferente, positivo y muy positivo* (rojo) indicando **asociación**, estar cerca del origen es una señal de que la mayoría de los encuestados comparte sentimientos positivos hacia las normas y encuentra fácil actuar conforme a la ley. **Asociación clave:** la cercanía entre *nunca* (p17b_FACL=1_n) y *negativo* (p16_PNOR=2_neg) confirma que quienes nunca cumplen la ley tienden a mostrar sentimientos negativos ante las normas o reglas.

- El **centro del plano** concentra las modalidades más frecuentes: sentimientos positivos y “casi siempre” / “siempre” cumplir la ley. Refleja la opinión de la mayoría.
- Las modalidades **muy negativo** y **nunca/casi nunca** se encuentran lejos del origen, indicando que tienen bajas frecuencias y que **distinguen más** a los encuestados.
- La **cercanía** entre *p16 muy_negativo* y *p17b nunca/casi_nunca* sugiere asociación: quienes tienen sentimientos muy negativos hacia las normas tienden a reportar que nunca o casi nunca les queda fácil cumplir la ley.
- La mayoría de los encuestados reporta sentimientos **positivos o muy positivos** hacia las normas, y simultáneamente que **siempre o casi siempre** les queda fácil actuar conforme a la ley.

Variable suplementaria: nivel educativo




UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

¿Tienen los niveles educativos más altos mayor facilidad para cumplir la ley o mejores sentimientos hacia las normas?


```
1 Nedx17 <- table(CCLatin$P7_Ned, CCLatin$P17_b)
2 pnor_Ned_faci <- rbind(as.data.frame.matrix(t16x17), as.data.frame.matrix(Nedx17))
3 ca_supl <- CA(pnor_Ned_faci, row.sup = 6:11, graph = FALSE)

1 plot.CA(ca_supl, title = "Sentimientos, facilidad para cumplir la ley y nivel educativo (suplementario)")
```



Variable suplementaria: indicadores por nivel educativo

Nivel educativo	Coordenadas		Cos ²	
	F1	F2	F1	F2
0 Sin educacion	-0.32	-0.07	0.72	0.04
1 Primaria	-0.07	0.07	0.41	0.42
2 Secundaria	0.09	0.04	0.74	0.11
3 Tecnico	0.04	0.02	0.34	0.10
4 Universitaria	0.03	-0.12	0.06	0.94
5 Posgrado	-0.20	-0.09	0.55	0.11



Note

Las variables suplementarias solo tienen coordenadas y Cos² (no contribuciones). **Sin educación** y **Posgrado** tienen las mayores coordenadas negativas sobre F1 (-0.32 y -0.20). La mejor representada es **Sin educación** (cos²=0.72); **Posgrado** alcanza cos²=0.55, suficiente para estar bien representada en F1. Ambos niveles se proyectan del mismo lado que *muy positivo* y *siempre fácil cumplir la ley*, lo que podría indicar asociación con encuestados que tienen sentimientos muy positivos hacia las normas y alta facilidad para acatarlas.



Ejemplo 2: Confianza en la justicia en 38 países

La **Encuesta Mundial de Valores** se realiza periódicamente desde 1981 e indaga opiniones sobre democracia, tolerancia, religión, medio ambiente y diversidad, entre otros temas.

Una de sus preguntas interroga por el **grado de confianza en la justicia** en 38 países, incluyendo varios latinoamericanos. La variable-fila es el **país** y la variable-columna es el **nivel de confianza** declarado por los encuestados.

```
1 library(pacman)
2 p_load(tidyverse, janitor, FactoMineR, factoextra, corrplot)
3
4 conf_just <- read.csv2(paste0(url, "ConfianzaJUsticia.csv")) |>
5   column_to_rownames("Pais") |>
6   arrange(desc(muchis.))
```

Tabla de contingencia: Países × Niveles de confianza




Grados de confianza en la justicia (Encuesta Mundial de Valores)

País	muchis.	mucho	no_mucho	nada	no_sabe	
Dinamarca	861	2	536	85	41	5
Alemania	549	2	952	195	119	15
Canadá	375	2	1	324	0	0
Austria	332	860	361	77	17	4
Rumania	323	833	928	598	168	23
Suiza	317	2	787	126	44	19
R Unido	317	819	521	104	31	1
Noruega	299	666	131	15	13	0
E Unidos	289	1	909	173	3	27
Australia	254	814	569	155	0	21
Finlandia	241	721	201	34	19	3
Suecia	219	692	218	39	29	1
Nueva Zelanda	213	504	247	39	20	0
Brasil	208	678	404	408	60	4
Países Bajos	205	1	802	151	135	5
Francia	189	907	525	211	47	1
Hunaria	156	578	509	234	31	11

```
1 acs_conf <- CA(conf_just, graph = FALSE)
2 #round(get_eigenvalue(acs_conf), 3)


1 fviz_eig(acs_conf, addlabels = TRUE, barfill = "#0077b6", barcolor = "#0077b6", linecolor = "#C0392B")
2 labs(title = "Gráfico de sedimentación - Confianza en la justicia", x = "Dimensión", y = "% inercia e
```



Plano de columnas: niveles de confianza




```
1 fviz_ca_col(acs_conf, repel = TRUE,  
2             col.col = "contrib",  
3             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
4             title = "Niveles de confianza - por contribución") + theme_bw()
```



Plano de filas: países




```
1 fviz_ca_row(acs_conf, repel = TRUE, labelsize = 3,  
2 col.row = "cos2",  
3 gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
4 title = "Países - grado de confianza en la justicia (cos²)" + theme_bw())
```



Representación simultánea: países y niveles de confianza



```
1 fviz_ca_biplot(acs_conf, repel = TRUE, labelsize = 3,  
2 col.row = "#0077b6", col.col = "#C0392B",  
3 title = "Asociación entre países y niveles de confianza en la justicia") +  
4 theme_bw()
```



- Los países cercanos al **extremo positivo del Factor 1** se caracterizan por una **alta proporción de confianza** (“mucho” o “bastante”) en la justicia.
- Los países en el extremo **negativo del Factor 1** presentan **baja o ninguna confianza** en la justicia.
- Los países cercanos al **origen del plano** tienen distribuciones similares al promedio mundial.
- Los países en extremos **opuestos del eje 2** difieren en los grados intermedios de confianza.
- Los países latinoamericanos tienden a agruparse, reflejando patrones culturales comunes respecto a la percepción del sistema judicial.



Ejemplo 3: Elecciones Alcaldía de Bogotá 2023

Contexto

En contextos electorales, identificar la percepción ciudadana hacia los candidatos resulta fundamental. Los datos analizados provienen de una muestra aleatoria de 300 personas, extraída de un estudio con 4894 encuestas aplicadas en todas las localidades de Bogotá. El instrumento evaluó a los candidatos a la Alcaldía de Bogotá 2023 mediante preguntas de selección múltiple, donde los participantes asignaron diversos atributos a cada perfil.

La tabla resultante es:

Dimensión	Descripción
Filas	26 atributos percibidos (positivos, negativos, ideológicos, de alineación política)
Columnas	9 candidatos (incluye “Ninguno” y “Ns/Nr”)

El ACS permite construir el **mapa perceptivo** de los candidatos.

Diseño del cuestionario

Se entrega a los entrevistados una tarjeta con la imagen y nombres de los candidatos. Luego se les muestra los atributos y para cada uno el encuestado responde con cuál(es) candidatos lo asocia.



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

21. De los siguientes personajes cuáles en su opinión cumplen con los siguientes atributos. Para cada atributo puede escoger un solo candidato, varios o ninguno. (Prog.: RM por fila/atributo. sólo mostrar los candidatos de la tabla que el encuestado/informante dijo conocer en P11. E: leer | tabla, mostrar tarjeta 1)

Atributo	Carlos Fernando Gálán	Gustavo Bolívar	Juan Daniel Ortíz	Rodrigo Lara	Diego Molano	Jorge Enrique Rivas	Jorge Luis Vargas	Ninguno	N/A (E: no lee)
Representa la continuidad de Claudia	1	2	3	4	5	6	7	8	9
Es el de más tendencia política de izquierda	1	2	3	4	5	6	7	8	9
Es el que garantiza mano dura en seguridad	1	2	3	4	5	6	7	8	9
Es el de más tendencia política de derecha	1	2	3	4	5	6	7	8	9
Es el que representa a Petro en Bogotá	1	2	3	4	5	6	7	8	9
Es el que tiene las mejores propuestas	1	2	3	4	5	6	7	8	9
Es el que representa un peligro para Bogotá	1	2	3	4	5	6	7	8	9
Es el candidato más respetuoso	1	2	3	4	5	6	7	8	9
Es el más conciliador / que garantiza el diálogo	1	2	3	4	5	6	7	8	9
Es el que garantiza políticas para cuidar / proteger a las mujeres	1	2	3	4	5	6	7	8	9
Es el que garantiza que Bogotá va a avanzar	1	2	3	4	5	6	7	8	9
Es el que respeta y garantiza la diversidad en la ciudad	1	2	3	4	5	6	7	8	9
Es el que puede diseñar e implementar una verdadera política de seguridad	1	2	3	4	5	6	7	8	9
Es el que más apoyo tiene de los empresarios	1	2	3	4	5	6	7	8	9
Es el de mayor sensibilidad social	1	2	3	4	5	6	7	8	9
Es la mejor persona	1	2	3	4	5	6	7	8	9
Es el clientelista	1	2	3	4	5	6	7	8	9
Es un candidato tibia / sin posiciones	1	2	3	4	5	6	7	8	9
Es un delfín	1	2	3	4	5	6	7	8	9
Es el que se ha destacado en los cargos que ha ocupado	1	2	3	4	5	6	7	8	9
Es el mejor orador / comunicador	1	2	3	4	5	6	7	8	9
Es el más auténtico / sincero	1	2	3	4	5	6	7	8	9
Es el candidato de Álvaro Uribe	1	2	3	4	5	6	7	8	9
Es el candidato de Páez	1	2	3	4	5	6	7	8	9
Es el candidato de Germán Vargas Lleras	1	2	3	4	5	6	7	8	9
Es el candidato de Rodolfo Hernández	1	2	3	4	5	6	7	8	9



```
1 library(pacman)
2 p_load(here, tidyverse, FactoMineR, factoextra, corrplot,
3        ggrepel, gt, janitor, haven)
4
5 url <- "https://github.com/jgbabativam/Curso_Multivariado/raw/main/Datos/"
6 clase <- read_sav(paste0(url, "df_clase.sav"))
```

Explore el conjunto de datos con `glimpse(as_factor(clase))` y compare con el cuestionario

Ordenar y transformar

wide

id x y z

1	a	c	e
2	b	d	f

Fuente: tidyexplain

Preparación de los datos



```
1 df_long <- clase |>
2   pivot_longer(cols = starts_with("P21"), names_to = "P21", values_to = "respuesta") |>
3   filter(!is.na(respuesta))
4
5 max_dig <- max(nchar(as.character(as.numeric(df_long$respuesta))), na.rm = TRUE)
6 cols_resp <- paste0("r_", 0:max_dig)
7
8 df1 <- df_long |>
9   mutate(respuesta = as.character(as.numeric(respuesta))) |>
10  filter(!is.na(respuesta)) |>
11  separate(respuesta, into = cols_resp, sep = "", fill = "right") |>
12  select(-r_0)
13
14 df_reest <- df1 |>
15  pivot_longer(cols = starts_with("r_"),
16             names_to = "var", values_to = "candidato",
17             values_drop_na = TRUE) |>
18  filter(candidato != "" & candidato != "0") |>
19  select(-var) |>
20  separate(P21, c("pregunta", "item"), sep = "_") |>
21  mutate(
22    item = factor(as.integer(item), levels = 1:26,
23                 labels = c("Continuidad Claudia", "Izquierda", "Mano dura",
24                           "Derecha", "Representa Petro", "Mejores propuestas",
25                           "Delicados/Bastión", "Mis propuestas", "Mis conciliadores")
```

Tabla de contingencia: atributos × candidatos




```
1 tabla_cand <- df_reest |>
2   count(item, candidato) |>
3   pivot_wider(names_from = candidato, values_from = n, values_fill = 0) |>
4   column_to_rownames("item")
```

Atributo	C.F. Galán	G. Bolívar	J.D. Oviedo	R. Lara	D. Molano	J.E. Robledo	J.L. Vargas	Ninguno	Ns/Nr
Continuidad Claudia	116	26	53	14	10	23	5	82	17
Izquierda	27	160	12	8	5	15	3	58	25
Mano dura	88	23	22	29	48	12	30	65	19
Derecha	97	15	35	35	54	11	18	63	24
Representa Petro	16	173	10	4	4	6	3	72	22
Mejores propuestas	123	47	45	19	14	13	8	60	21
Peligro p/Bogotá	16	100	26	18	35	15	13	107	25
Más respetuoso	114	43	73	26	20	22	15	40	20
Más conciliador	117	45	66	23	15	23	7	43	17
Protege mujeres	111	40	52	19	15	21	8	63	30
Bogotá avanza	140	48	39	16	16	19	8	65	13
Respeto diversidad	108	55	71	16	13	17	8	56	19
Política seguridad	100	34	31	20	32	16	28	73	16
Apoyo empresarial	132	17	23	21	29	13	12	58	36
Sanidad	87	66	69	29	19	29	7	69	29




```
1 res <- CA(tabla_cand, graph = FALSE)
2 fviz_screplot(res, addlabels = TRUE, ylim = c(0, 50), barfill = "#0077b6", barcolor = "#0077b6", linecolor = "red",
3   labs(title = "Gráfico de sedimentación - Candidatos Bogotá 2023",
4     x = "Dimensión", y = "% inercia explicada") + theme_bw())
```

Gráfico de sedimentación — Candidatos Bogotá 2023



Contribuciones de las columnas (candidatos)

```
1 corrplot(res$col$contrib, is.corr=FALSE, tl.col = "black")
```




Contribuciones de las filas (atributos)




UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

```
1 corrplot(res$row$contrib, is.corr=FALSE, tl.col = "black")
```



Análisis de los cosenos para los candidatos

```
1 corrpplot(res$col$cos2, is.corr=FALSE, tl.col = "black")
```




Análisis de los cosenos para los atributos



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ


```
1 corrpplot(res$row$cos2, is.corr=FALSE, tl.col = "black")
```



Perfil de los candidatos (Plano 1-2)




```
1 fviz_ca_col(res, repel = TRUE, col.col = "cos2", axes = c(1,2),  
2       gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
3       select.col = list(cos2 = 0.5))
```



Posicionamiento de los atributos (Plano 1-2)




```
1 fviz_ca_row(res, repel = TRUE, col.row = "cos2", axes = c(1,2),
2             gradient.cols = c("lightblue", "blue", "darkblue"),
3             select.row = list(cos2 = 0.5))
```



Biplot: candidatos y atributos



```
1 fviz_ca_biplot(res, axes = c(1,2),  
2               repel = TRUE,  
3               select.col = list(cos2 = 0.5),  
4               select.row = list(cos2 = 0.5))
```



Análisis complementarios

1. Haga un análisis que le permita encontrar las diferencias y similitudes entre los candidatos Galán, Oviedo, Molano y Vargas.
2. ¿Cuáles son los aspectos que diferencian al candidato Lara frente a los candidatos Galán y Oviedo?.
3. ¿Que modificación debe realizar si su objetivo se centra en encontrar los aspectos que diferencian al candidato Lara frente a los candidatos Molano y Vargas?.



UNIVERSIDAD
NACIONAL
DE COLOMBIA
SEDE BOGOTÁ

GRACIAS!

Citación y derechos de autor

Este material ha sido creado por Jimmy Corzo y [Giovany Babativa-Márquez](#) y es de libre distribución bajo la licencia [Creative Commons Attribution-ShareAlike 4.0](#).

Cualquier copia parcial o total de este material, debe citar la fuente como:

Corzo J., & Babativa-Márquez, J.G. *Diapositivas del curso de estadística descriptiva multivariada*. URL:
https://jgbabativam.github.io/Curso_Multivariado/