

# Metodología Box–Jenkins

Un enfoque orientado a la toma de decisiones

## Resumen

Este documento organiza la metodología Box–Jenkins para modelos ARIMA/SARIMA en sus cuatro fases clásicas —*identificación, estimación, validación y uso del modelo*— pero con énfasis en **qué decisión tomar en cada punto del proceso**. Cada sección incluye: (i) el fundamento teórico mínimo, (ii) una tabla de decisión con criterios explícitos, y (iii) un diagrama de flujo que resume la lógica del paso. Se agregan además el ciclo iterativo completo, el principio de parsimonia y la validación fuera de muestra (*out-of-sample*), que complementan el esquema original.


## Índice

|          |                                                                        |           |
|----------|------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Panorama general: el ciclo iterativo de Box–Jenkins</b>             | <b>2</b>  |
| <b>2</b> | <b>Fase 1: Identificación del modelo</b>                               | <b>3</b>  |
| 2.1      | Paso 1.1 — Estacionariedad . . . . .                                   | 3         |
| 2.2      | Paso 1.2 — Estacionalidad . . . . .                                    | 3         |
| 2.3      | Paso 1.3 — Identificación de $p$ y $q$ vía ACF / PACF . . . . .        | 3         |
| 2.4      | Paso 1.4 — Supuestos para poder usar ARMA . . . . .                    | 4         |
| <b>3</b> | <b>Fase 2: Estimación de parámetros</b>                                | <b>5</b>  |
| 3.1      | Métodos de estimación . . . . .                                        | 5         |
| 3.2      | Inferencia sobre los coeficientes (MLE) . . . . .                      | 5         |
| 3.3      | Selección de modelo: criterios de información . . . . .                | 5         |
| <b>4</b> | <b>Fase 3: Validación del modelo</b>                                   | <b>7</b>  |
| 4.1      | Análisis de residuales . . . . .                                       | 7         |
| 4.2      | Inferencia con bootstrap . . . . .                                     | 7         |
| <b>5</b> | <b>Complemento: validación fuera de muestra (<i>out-of-sample</i>)</b> | <b>9</b>  |
| <b>6</b> | <b>Fase 4: Uso del modelo — pronóstico e incertidumbre</b>             | <b>9</b>  |
| 6.1      | Tipos de incertidumbre predictiva . . . . .                            | 9         |
| 6.2      | El mejor predictor . . . . .                                           | 9         |
| 6.3      | Intervalos y distribuciones predictivas . . . . .                      | 10        |
| 6.4      | Evaluación de intervalos: Winkler score . . . . .                      | 10        |
| <b>7</b> | <b>Complementos metodológicos adicionales</b>                          | <b>10</b> |
| 7.1      | Transformación de la varianza y tratamiento de atípicos . . . . .      | 11        |
| 7.2      | Verificación de sobreajuste ( <i>overfitting check</i> ) . . . . .     | 11        |
| 7.3      | Variables exógenas: ARIMAX / SARIMAX . . . . .                         | 11        |
| 7.4      | Selección automática vs. manual del modelo . . . . .                   | 11        |
| 7.5      | ARIMA/SARIMA frente a métodos alternativos . . . . .                   | 12        |
| 7.6      | Monitoreo y actualización del modelo en producción . . . . .           | 12        |

**8 Resumen: árbol de decisión integral****13**

## 1 Panorama general: el ciclo iterativo de Box–Jenkins

Box–Jenkins no es un proceso lineal sino **iterativo**: si el modelo falla la validación, se regresa a la identificación. La decisión maestra es siempre la misma: *¿el modelo actual satisface los supuestos y predice razonablemente bien con el menor número de parámetros posible?* (principio de **parsimonia**).



### Regla de decisión

Elija siempre el modelo **más simple** que cumpla los supuestos y minimice un criterio de información. Si dos modelos son estadísticamente equivalentes en validación, prediga con ambos y compare error fuera de muestra antes de decidir.

## 2 Fase 1: Identificación del modelo

El objetivo es decidir la estructura  $(p, d, q) \times (P, D, Q)_s$  antes de estimar nada.

### 2.1 Paso 1.1 — Estacionariedad

| Prueba                        | $H_0$                                  | Si se rechaza $H_0$         | Decisión                    |
|-------------------------------|----------------------------------------|-----------------------------|-----------------------------|
| ADF (Dickey–Fuller aumentada) | Existe raíz unitaria (no estacionaria) | La serie es estacionaria    | No diferenciar ( $d = 0$ )  |
| KPSS                          | La serie es estacionaria               | La serie NO es estacionaria | Diferenciar ( $d = d + 1$ ) |
| Phillips–Perron               | Existe raíz unitaria                   | La serie es estacionaria    | Confirma ADF                |

#### Regla de decisión

Use ADF y KPSS **en conjunto** (nunca solo una):

- ADF rechaza y KPSS no rechaza  $\rightarrow$  estacionaria,  $d = 0$ .
- ADF no rechaza y KPSS rechaza  $\rightarrow$  no estacionaria, diferenciar.
- Resultados contradictorios  $\rightarrow$  inspeccionar gráfico de la serie y su varianza; considerar tendencia determinística vs. estocástica.

Evite sobre-diferenciar: si tras diferenciar el ACF muestra un pico negativo fuerte en lag 1 cercano a  $-0.5$ , probablemente ya diferenció de más.


### 2.2 Paso 1.2 — Estacionalidad

#### Regla de decisión

- Si el correlograma muestra picos significativos en múltiplos del periodo  $s$  (12, 4, 7, etc.) que *no* decaen  $\rightarrow$  aplicar diferenciación estacional  $D = 1$  y modelar con **SARIMA**.
- Si tras diferenciar estacionalmente persisten picos  $\rightarrow$  aumentar  $D$  (rara vez  $D > 1$ ).
- Si no hay patrón periódico claro  $\rightarrow$  usar **ARIMA** sin componente estacional.

### 2.3 Paso 1.3 — Identificación de $p$ y $q$ vía ACF / PACF

| Patrón ACF                   | Patrón PACF                  | Modelo sugerido     | Orden         |
|------------------------------|------------------------------|---------------------|---------------|
| Decae exponencial/sinusoidal | Corte abrupto en lag $p$     | AR( $p$ )           | $p$           |
| Corte abrupto en lag $q$     | Decae exponencial/sinusoidal | MA( $q$ )           | $q$           |
| Decae gradualmente           | Decae gradualmente           | ARMA( $p, q$ )      | probar varios |
| Ambos cortan / mixto         | Ambos cortan / mixto         | Comparar candidatos | usar IC       |



## 2.4 Paso 1.4 — Supuestos para poder usar ARMA

Para que un proceso  $\{e_t\}$  pueda tratarse como ruido blanco (base de ARMA) debe cumplir:

| Supuesto          | Qué implica                                         | Cómo verificarlo                        |
|-------------------|-----------------------------------------------------|-----------------------------------------|
| Media cero        | $E[e_t] = 0$                                        | prueba $t$ sobre la media de residuales |
| Homoscedasticidad | $Var(e_t) = \sigma^2$ constante                     | ARCH-LM, Breusch–Pagan                  |
| No correlación    | $Cov(e_t, e_{t-k}) = 0, k \neq 0$                   | Ljung–Box, correlograma                 |
| Normalidad        | $e_t \sim N(0, \sigma^2)$ (para inferencia clásica) | Jarque–Bera, Shapiro–Wilk, Q-Q plot     |

### Regla de decisión

Estos cuatro supuestos se verifican formalmente **después** de estimar (Fase 3), pero se anticipan aquí porque condicionan la elección del modelo: si se sospecha heteroscedasticidad desde la identificación (varianza que crece con el nivel), transforme la serie (log, Box–Cox) **antes** de identificar  $p, d, q$ .

### 3 Fase 2: Estimación de parámetros

#### 3.1 Métodos de estimación

| Método                                  | Idea                                                     | Cuándo usarlo                                                                                                |
|-----------------------------------------|----------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|
| Método de momentos                      | Iguala momentos muestrales (media, ACF) a los teóricos   | Rápido; da <b>valores iniciales</b> para optimizar MLE. No usar como estimador final en modelos con MA.      |
| Mínimos cuadrados (MCO / condicionales) | Minimiza $\sum \hat{e}_t^2$                              | Modelos puramente AR; simple e interpretable; pierde eficiencia si hay componente MA.                        |
| Máxima verosimilitud (MLE)              | Maximiza $L(\theta   y)$ asumiendo distribución de $e_t$ | Estándar de facto para ARMA/ARIMA/SARIMA; necesario cuando hay componente MA; más eficiente asintóticamente. |

##### Regla de decisión

- Si el modelo es AR puro y  $n$  grande  $\rightarrow$  MCO es suficiente y más barato computacionalmente.
- Si hay componente MA o ARMA mixto  $\rightarrow$  use MLE (los software estadísticos usan momentos/MCO solo como valores semilla del optimizador numérico).
- Si  $n$  es pequeño o hay dudas de normalidad  $\rightarrow$  complemente MLE con bootstrap (ver Fase 3) en lugar de confiar solo en errores estándar asintóticos.

#### 3.2 Inferencia sobre los coeficientes (MLE)

Bajo condiciones de regularidad, el estimador MLE  $\hat{\theta}$  es asintóticamente normal:

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1})$$

donde  $I(\theta_0)$  es la información de Fisher. Esto permite construir:

$$\hat{\theta}_j \pm z_{\alpha/2} \widehat{SE}(\hat{\theta}_j)$$

para pruebas de significancia individuales (Wald) sobre cada coeficiente AR/MA.

##### Regla de decisión

Si el intervalo de confianza de un coeficiente incluye el cero  $\rightarrow$  considere eliminarlo (reducir  $p$  o  $q$ ) y re-estimar, salvo que la teoría del fenómeno exija mantenerlo.

#### 3.3 Selección de modelo: criterios de información

$$AIC = -2 \log L + 2k, \quad BIC = -2 \log L + k \log n, \quad AICc = AIC + \frac{2k(k+1)}{n-k-1}$$

| Criterio | Comportamiento                                              | Úselo cuando                                                    |
|----------|-------------------------------------------------------------|-----------------------------------------------------------------|
| AIC      | Penaliza poco la complejidad; tiende a sobreparametrizar    | El objetivo es predicción y $n$ moderado/grande                 |
| BIC      | Penaliza más fuerte $\Rightarrow$ modelos más parsimoniosos | El objetivo es identificar el “verdadero” modelo con $n$ grande |
| AICc     | Corrige el sesgo de AIC en muestras pequeñas                | $n$ pequeño relativo a $k$                                      |

**Regla de decisión**

Ajuste varios candidatos razonables (de la Fase 1) y elija el de **menor IC**. Si AIC y BIC sugieren modelos distintos, prefiera el de BIC si su objetivo es inferencia/parsimonia, y el de AIC si su objetivo es puramente predictivo; en caso de duda, valide ambos fuera de muestra (Sección 5).

## 4 Fase 3: Validación del modelo

### 4.1 Análisis de residuales

| Supuesto re-<br>visado | Prueba                            | Detecta                  | Si falla                                                  |
|------------------------|-----------------------------------|--------------------------|-----------------------------------------------------------|
| Media cero             | prueba $t$ sobre residuales       | sesgo sistemático        | falta constante/tendencia; re-especificar                 |
| Homoscedasticidad      | ARCH-LM, Breusch–Pagan            | varianza no constante    | modelar volatilidad (GARCH) o transformar (log/Box–Cox)   |
| No correlación         | Ljung–Box, ACF/PACF de residuales | dependencia no capturada | aumentar $p/q$ , revisar $d$                              |
| Normalidad             | Jarque–Bera, Shapiro–Wilk         | colas pesadas/asimetría  | usar bootstrap para inferencia, no confiar en IC clásicos |
| Independencia          | Durbin–Watson, gráficos           | estructura residual      | revisar outliers, quiebres, no linealidad                 |

#### Si el supuesto falla

- **No hay media cero:** el modelo está mal especificado (falta drift o variable exógena) → regrese a Fase 1.
- **Heteroscedasticidad:** los intervalos de predicción clásicos serán incorrectos → combine ARIMA con GARCH o transforme la serie.
- **Correlación residual:** el modelo dejó señal sin explicar → incremente  $p/q$  o reconsidere  $d/D$ .
- **No normalidad:** los errores estándar de MLE e intervalos gaussianos pierden validez → use **bootstrap** (siguiente subsección).
- **No independencia:** puede haber estructura no lineal (asimetrías, cambios de régimen) → considerar modelos no lineales o por tramos.

### 4.2 Inferencia con bootstrap

| Método                       | Cómo funciona                                                                                                                         | Cuándo preferirlo                                                                                         |
|------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| Bootstrap clásico (residuos) | Re-muestrea con reemplazo los residuales estimados, reconstruye trayectorias sintéticas con el modelo ajustado y re-estima            | Modelo bien especificado, se duda solo de la normalidad                                                   |
| AR-Sieve bootstrap           | Aproxima el proceso con un $AR(p_n)$ cuyo orden crece con $n$ (“sieve”), preservando la dependencia sin imponer la forma AR-MA exacta | Incertidumbre sobre la especificación correcta del modelo, dependencia compleja o modelo mal especificado |

**Regla de decisión**

- Si la validación de normalidad falla pero el modelo pasa las demás pruebas  $\rightarrow$  bootstrap clásico de residuos es suficiente.
- Si además hay dudas sobre la forma funcional o el orden del modelo  $\rightarrow$  prefiera **sieve bootstrap**, más robusto a mala especificación.
- Use siempre bootstrap (en vez de fórmulas asintóticas) cuando  $n$  sea pequeño.

## 5 Complemento: validación fuera de muestra (*out-of-sample*)

Los diagnósticos de residuales validan el ajuste *dentro* de muestra; para decidir si el modelo sirve para pronosticar se necesita evaluar *fuera* de muestra.

### Regla de decisión

- Divida la serie en entrenamiento/prueba (*rolling origin* o *expanding window*), nunca de forma aleatoria (respete el orden temporal).
- Compare candidatos con métricas de error puntual: RMSE, MAE, MAPE.
- Compare intervalos de predicción con el **Winkler score** (Sección 6.4).
- Si el ranking por IC (Fase 2) y el ranking por error fuera de muestra difieren, priorice el error fuera de muestra: es la evidencia más directa de capacidad predictiva real.

## 6 Fase 4: Uso del modelo — pronóstico e incertidumbre

### 6.1 Tipos de incertidumbre predictiva

| Tipo                               | Origen                                             | Reducible con más datos? |
|------------------------------------|----------------------------------------------------|--------------------------|
| Aleatoria<br>( <i>aleatoric</i> )  | Ruido inherente del proceso $e_t$                  | No                       |
| Epistémica<br>( <i>epistemic</i> ) | Incertidumbre sobre los parámetros/modelo estimado | Sí                       |

$$\underbrace{Var(Y_{t+h} | \mathcal{F}_t)}_{\text{incertidumbre total}} = \underbrace{Var(Y_{t+h} | \theta, \mathcal{F}_t)}_{\text{aleatoria}} + \underbrace{Var(E[Y_{t+h} | \theta, \mathcal{F}_t] | \hat{\theta})}_{\text{epistémica (parámetros)}}$$

### Regla de decisión

- Con muestras grandes y modelo bien especificado, la incertidumbre epistémica es pequeña y los intervalos clásicos (asumiendo  $\theta$  conocido) son razonables.
- Con  $n$  pequeño, modelo posiblemente mal especificado, o pronósticos a horizontes largos  $\rightarrow$  la incertidumbre epistémica domina; use **bootstrap** (clásico o sieve) para incorporarla en los intervalos.

### 6.2 El mejor predictor

Bajo pérdida cuadrática, el predictor óptimo (MMSE) es la esperanza condicional:

$$\hat{Y}_{t+h|t} = E[Y_{t+h} | \mathcal{F}_t]$$

Para un proceso ARMA estacionario, cuando  $h \rightarrow \infty$ :

$$\hat{Y}_{t+h|t} \rightarrow \mu, \quad Var(Y_{t+h} - \hat{Y}_{t+h|t}) \rightarrow \gamma_0$$

es decir, el pronóstico converge a la media incondicional y la incertidumbre a la varianza incondicional del proceso: el modelo “olvida” la información reciente a medida que el horizonte crece.

**Regla de decisión**

Si el horizonte de pronóstico requerido es mucho mayor que la memoria efectiva del proceso (dada por la magnitud de las raíces AR), advierta que el pronóstico puntual aportará poco más que la media histórica; comuníquese esto junto con el intervalo.

**6.3 Intervalos y distribuciones predictivas**

| Enfoque                                | Descripción                                                                                                                   | Cuándo usarlo                                                                                   |
|----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| Intervalo gaussiano clásico            | $\hat{Y} \pm z_{\alpha/2} \sqrt{\widehat{Var}}$ , asume normalidad y $\theta$ conocido                                        | Residuales normales, $n$ grande                                                                 |
| Distribución predictiva por remuestreo | Se simulan trayectorias futuras re-muestreando residuos (bootstrap clásico o sieve), incorporando incertidumbre de parámetros | Residuales no normales, $n$ pequeño, o se busca la distribución completa (no solo un intervalo) |

**6.4 Evaluación de intervalos: Winkler score**

Para un intervalo de  $(1 - \alpha)$  de confianza  $[l_t, u_t]$  y observación real  $y_t$ :

$$W_{\alpha}(l_t, u_t, y_t) = \begin{cases} (u_t - l_t) & \text{si } l_t \leq y_t \leq u_t \\ (u_t - l_t) + \frac{2}{\alpha}(l_t - y_t) & \text{si } y_t < l_t \\ (u_t - l_t) + \frac{2}{\alpha}(y_t - u_t) & \text{si } y_t > u_t \end{cases}$$

**Regla de decisión**

Un intervalo angosto que casi nunca cubre la observación real será penalizado con un Winkler score alto (malo), igual que uno demasiado ancho. Compare candidatos por el **Winkler score promedio** fuera de muestra: menor es mejor. Úselo, junto con RMSE/MAE, como criterio final para elegir entre modelos que ya pasaron la validación de residuales.

**7 Complementos metodológicos adicionales**

El esquema clásico de 4 fases asume implícitamente una serie "limpia" y un único modelo lineal candidato. En la práctica hay decisiones adicionales que casi siempre aparecen y que conviene anticipar.

## 7.1 Transformación de la varianza y tratamiento de atípicos

### Regla de decisión

- Si la dispersión de la serie crece con el nivel (varianza no constante *antes* de diferenciar) → aplique log o Box–Cox **antes** de identificar  $(p, d, q)$ , no después.
- Un solo pico aislado y grande en el residual → posible **atípico aditivo (AO)**: afecta una sola observación; trátelo con una variable dummy puntual.
- Un pico que se propaga y decae según la dinámica del modelo → **atípico innovacional (IO)**: afecta el choque  $e_t$ , no la observación; suele resolverse solo si el modelo está bien especificado.
- Un cambio permanente de nivel que no revierte → **cambio de nivel (LS)**: use una variable escalón (*step dummy*) desde ese punto en adelante; si no se corrige, contamina toda la estimación de  $\phi, \theta$ .
- Un cambio temporal que decae gradualmente a la serie original → **cambio transitorio (TC)**: dummy con decaimiento exponencial.

Ignorar atípicos no es neutral: sesgan los coeficientes AR/MA y inflan la varianza residual, lo que a su vez ensancha innecesariamente los intervalos de predicción.

## 7.2 Verificación de sobreajuste (*overfitting check*)

Tras elegir el modelo por AIC/BIC, es buena práctica **sobre-ajustar deliberadamente**: estimar una versión con un parámetro AR o MA adicional ( $p + 1$  o  $q + 1$ ) y observar si ese coeficiente extra resulta significativo.

### Regla de decisión

- Coeficiente adicional **no significativo** y el resto del modelo no cambia sustancialmente → confirma que el modelo original era adecuado (parsimonia validada).
- Coeficiente adicional **significativo** → el modelo original estaba sub-ajustado; incorpore el término y repita la validación (Fase 3).

## 7.3 Variables exógenas: ARIMAX / SARIMAX

Si tras un buen ajuste ARIMA los residuales siguen correlacionados con una variable externa conocida (feriados, promociones, temperatura, variables macro), la solución no es seguir aumentando  $p$  o  $q$ .

### Regla de decisión

Incorpore la variable como regresor exógeno (ARIMAX/SARIMAX) en lugar de forzar más estructura autorregresiva. Señal típica de que hace falta: los residuales del ARIMA puro muestran patrones alineados con eventos conocidos (picos en fechas fijas, quiebres coincidentes con una intervención), no con rezagos de la propia serie.

## 7.4 Selección automática vs. manual del modelo

Herramientas como `auto.arima` (R) o `pmdarima` (Python) automatizan la búsqueda por combinaciones de  $(p, d, q)$  vía criterios de información.

**Regla de decisión**

- Úselas como **punto de partida rápido**, nunca como decisión final.
- Siempre confirme manualmente: (i) el orden de diferenciación sugerido contra sus propias pruebas ADF/KPSS, (ii) los residuales del modelo automático contra la batería completa de la Fase 3.
- Los algoritmos automáticos pueden fallar ante quiebres estructurales, atípicos no tratados, o estacionalidades múltiples; en esos casos el criterio experto (inspección de ACF/PACF, conocimiento del fenómeno) debe prevalecer.

**7.5 ARIMA/SARIMA frente a métodos alternativos**

| Método alternativo                           | Cuándo puede superar a Box–Jenkins                                                                            | Costo                                                                     |
|----------------------------------------------|---------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------|
| Suavizado exponencial (ETS)                  | Series cortas, tendencia/estacionalidad simple y estable                                                      | Menos flexible ante autocorrelación compleja                              |
| Modelos estructurales de espacio de estados  | Se necesita descomponer explícitamente nivel/tendencia/estacionalidad con incertidumbre propia por componente | Mayor complejidad de especificación                                       |
| Modelos de machine learning (árboles, redes) | Muchas variables predictoras, relaciones no lineales, datos abundantes                                        | Pierde interpretabilidad y los supuestos de esta guía ya no aplican igual |

**Regla de decisión**

Ante series cortas y de comportamiento simple, compare siempre ARIMA/SARIMA contra un ETS como *benchmark* mínimo: si ETS predice igual o mejor fuera de muestra con menos supuestos, prefiera el modelo más simple (parsimonia también aplica *entre* familias de modelos, no solo dentro de ARIMA).


**7.6 Monitoreo y actualización del modelo en producción**

Un modelo validado hoy no permanece válido indefinidamente si el proceso generador de datos cambia (*concept drift*).

**Regla de decisión**

- Re-estime periódicamente con ventana móvil o expansiva y compare parámetros: cambios grandes y sistemáticos sugieren que el proceso ya no es el mismo.
- Lleve un control tipo CUSUM sobre los errores de pronóstico; si se acumulan errores sistemáticos en una dirección, es señal de re-especificar, no solo de re-estimar.
- Documente cada re-especificación como una vuelta completa al ciclo de la Sección 1: no basta con "actualizar coeficientes" si cambió la estructura misma del proceso.

## 8 Resumen: árbol de decisión integral



**Regla de decisión**

**Regla maestra:** en cada bifurcación, prefiera siempre la opción que (1) resuelva la violación detectada, (2) mantenga el modelo lo más simple posible, y (3) se confirme con evidencia fuera de muestra antes de reportarse como definitiva.