

Pruebas Estadísticas Formales

en la Metodología Box–Jenkins, y Resumen General (Cheat Sheet)

Resumen

Primera parte: definición formal —hipótesis, estadístico de prueba, distribución y regla de decisión— de las pruebas mencionadas a lo largo de los documentos anteriores (ADF, PP, KPSS, Ljung–Box, Durbin–Watson, Breusch–Pagan, ARCH-LM, Jarque–Bera, Shapiro–Wilk). Segunda parte: una hoja de referencia rápida (*cheat sheet*) que condensa las tablas de decisión de identificación, estimación, validación y uso del modelo.

Índice

1	Pruebas de raíz unitaria y estacionariedad	2
2	Pruebas sobre los residuales	4
3	Cheat Sheet: resumen general de la metodología	6
4	Árbol de decisión integral	8

1 Pruebas de raíz unitaria y estacionariedad

Dickey–Fuller Aumentada (ADF)

Modelo auxiliar (con constante y tendencia):

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t$$

Hipótesis: $H_0 : \gamma = 0$ (existe raíz unitaria, y_t no estacionaria) vs. $H_1 : \gamma < 0$ (estacionaria).

Estadístico: $\tau = \hat{\gamma} / \widehat{SE}(\hat{\gamma})$. Bajo H_0 , τ **no** sigue una t -Student estándar (la distribución está sesgada a la izquierda); se compara contra las tablas de valores críticos de Dickey–Fuller/MacKinnon, que dependen de si se incluye constante y/o tendencia.

Los rezagos Δy_{t-i} se agregan para blanquear los residuales ε_t (de ahí "aumentada"); su número se elige por AIC/BIC o por la regla de Schwert.

Regla de decisión

Si τ es más negativo que el valor crítico $\rightarrow$ se rechaza $H_0 \rightarrow$ la serie es estacionaria (no requiere diferenciar).
Si no se rechaza $\rightarrow$ diferenciar y repetir la prueba sobre ∇y_t .

Phillips–Perron (PP)

Misma hipótesis y misma regresión base que ADF ($H_0 : \gamma = 0$), pero en lugar de agregar rezagos de Δy_t para corregir la autocorrelación y heteroscedasticidad del error, PP corrige el estadístico **no paramétricamente** mediante un estimador tipo Newey–West de la varianza de largo plazo.

Regla de decisión

Interpretación idéntica a ADF (rechazar $H_0 \Rightarrow$ estacionaria). Se recomienda usar PP y ADF en conjunto: si coinciden, mayor confianza en la conclusión; si difieren, revisar la estructura de la serie (posibles quiebres, heteroscedasticidad fuerte).

KPSS (Kwiatkowski–Phillips–Schmidt–Shin)

Modelo: $y_t = \xi t + r_t + \varepsilon_t$, con $r_t = r_{t-1} + u_t$, $u_t \sim iid(0, \sigma_u^2)$ (una caminata aleatoria como componente de nivel).

Hipótesis: $H_0 : \sigma_u^2 = 0$ (no hay caminata aleatoria $\Rightarrow y_t$ es estacionaria, o estacionaria alrededor de tendencia si $\xi \neq 0$) vs. $H_1 : \sigma_u^2 > 0$ (raíz unitaria).

Estadístico:

$$LM = \frac{\sum_{t=1}^n S_t^2}{n^2 \hat{f}_0}, \quad S_t = \sum_{j=1}^t \hat{\varepsilon}_j$$

donde $\hat{\varepsilon}_j$ son los residuales de regresar y_t sobre una constante (o constante+tendencia), y $\hat{f}_0$ es un estimador de la varianza de largo plazo. Bajo H_0 , LM converge a una distribución no estándar (funcional de un puente browniano); se compara contra tablas de valores críticos de KPSS.

Regla de decisión

Si LM supera el valor crítico $\rightarrow$ se rechaza $H_0 \rightarrow$ la serie **NO** es estacionaria (diferenciar). Nótese que la hipótesis nula de KPSS es la **opuesta** a la de ADF/PP: por eso se usan en conjunto (ver tabla de combinación en el documento de metodología).

Nota

Para raíces unitarias **estacionales** (¿se requiere $(1 - L^s)$?), el análogo de ADF es la prueba **HEGY**, que descompone el polinomio estacional en factores asociados a cada frecuencia (cero, estacionales, Nyquist) y prueba raíces unitarias en cada una por separado, en lugar de asumir una única raíz unitaria estacional común.

2 Pruebas sobre los residuales

Ljung–Box (no autocorrelación)

Hipótesis: $H_0 : \rho(1) = \rho(2) = \dots = \rho(m) = 0$ (los residuales no están autocorrelacionados hasta el rezago m) vs. $H_1 : \text{algún } \rho(k) \neq 0$.

Estadístico:

$$Q(m) = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}(k)^2}{n-k}$$

donde $\hat{\rho}(k)$ son las autocorrelaciones muestrales de los residuales.

Distribución: bajo H_0 , $Q(m) \sim \chi^2_{(m-p-q)}$ aproximadamente, donde p, q son los órdenes AR y MA ya estimados (los grados de libertad se reducen porque esos parámetros ya "explicaron" parte de la dependencia).

Regla de decisión

Si $Q(m) > \chi^2_{1-\alpha, (m-p-q)}$ (o el p -valor $< \alpha$) $\rightarrow$ se rechaza $H_0 \rightarrow$ quedan autocorrelaciones sin explicar $\rightarrow$ aumentar p/q y re-estimar.

Durbin–Watson (autocorrelación de orden 1)

Estadístico:

$$DW = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=1}^n \hat{\varepsilon}_t^2} \approx 2(1 - \hat{\rho}_1)$$

Rango: $DW \in (0, 4)$. $DW \approx 2 \Rightarrow$ sin autocorrelación de orden 1; $DW < 2 \Rightarrow$ autocorrelación positiva; $DW > 2 \Rightarrow$ autocorrelación negativa.

Regla de decisión

Útil como diagnóstico rápido, pero **no válido** cuando el modelo incluye variables dependientes rezagadas como regresores (como ocurre siempre en un modelo AR/ARIMA): en ese caso el estadístico está sesgado hacia 2 y subestima la autocorrelación real. **Para modelos ARIMA use Ljung–Box, no Durbin–Watson.**

Breusch–Pagan (homoscedasticidad general)

Se regresan los residuales al cuadrado $\hat{\varepsilon}_t^2$ sobre un conjunto de variables z_t (p.ej. los valores ajustados, o covariables candidatas a explicar la varianza):

$$\hat{\varepsilon}_t^2 = \alpha_0 + \alpha_1 z_{1t} + \dots + \alpha_k z_{kt} + v_t$$

Hipótesis: $H_0 : \alpha_1 = \dots = \alpha_k = 0$ (varianza constante, no depende de z_t).

Estadístico: $LM = nR^2$ de esta regresión auxiliar, donde R^2 es el coeficiente de determinación. Bajo H_0 , $LM \sim \chi^2_{(k)}$.

Regla de decisión

Si $LM > \chi^2_{1-\alpha, (k)}$ $\rightarrow$ se rechaza $H_0 \rightarrow$ heterocedasticidad asociada a z_t (p.ej. la varianza crece con el nivel de la serie) $\rightarrow$ considerar transformación (log, Box–Cox).

ARCH-LM (heterocedasticidad condicional autorregresiva)

Se regresan los residuales al cuadrado sobre sus propios rezagos:

$$\hat{\varepsilon}_t^2 = \alpha_0 + \alpha_1 \hat{\varepsilon}_{t-1}^2 + \dots + \alpha_q \hat{\varepsilon}_{t-q}^2 + v_t$$

Hipótesis: $H_0 : \alpha_1 = \dots = \alpha_q = 0$ (no hay efecto ARCH: la varianza condicional no depende de choques)

pasados al cuadrado).

Estadístico: $LM = nR^2 \sim \chi^2_{(q)}$ bajo H_0 (equivalente a un Breusch–Pagan aplicado a los propios rezagos del residual al cuadrado).

Regla de decisión

Si se rechaza $H_0 \rightarrow$ hay clústeres de volatilidad (varianza que depende del pasado reciente) $\rightarrow$ modelar la varianza explícitamente con un modelo de la familia **GARCH** en vez de asumir varianza constante.

Jarque–Bera (normalidad)

Estadístico:

$$JB = \frac{n}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right)$$

donde S es el coeficiente de asimetría (*skewness*) muestral y K la curtosis muestral de los residuales.

Hipótesis: $H_0 : S = 0$ y $K = 3$ (consistente con normalidad).

Distribución: bajo H_0 , $JB \sim \chi^2_{(2)}$ asintóticamente.

Regla de decisión

Si $JB > \chi^2_{1-\alpha, (2)}$ $\rightarrow$ se rechaza normalidad $\rightarrow$ no usar errores estándar/intervalos gaussianos; preferir bootstrap para la inferencia.

Shapiro–Wilk (normalidad, muestras pequeñas)

Estadístico W basado en la correlación entre los residuales ordenados y los cuantiles esperados de una normal (fórmula más compleja que involucra combinaciones lineales óptimas de los estadísticos de orden); W cercano a 1 favorece normalidad.

Regla de decisión

Preferir Shapiro–Wilk sobre Jarque–Bera cuando n es pequeño (Jarque–Bera es un resultado asintótico y pierde precisión con muestras chicas). Si p -valor $< \alpha \rightarrow$ se rechaza normalidad.

3 Cheat Sheet: resumen general de la metodología

1. Identificación

Modelo	FAC	FACP	Condición clave
AR(p)	Decae expon./sinusoidal	Corte abrupto en p	Raíces de $\phi(z)$ fuera del círculo unitario
MA(q)	Corte abrupto en q	Decae expon./sinusoidal	Raíces de $\theta(z)$ fuera del círculo unitario (invertibilidad)
ARMA(p,q)	Decae (sin corte) tras q	Decae (sin corte)	Ambas condiciones simultáneas
ARIMA(p,d,q)	(de $\nabla^d y_t$) igual que ARMA	igual que ARMA	d = raíces unitarias regulares (ADF/KPSS)
SARIMA	Picos en múltiplos de s	Picos en múltiplos de s	D = raíz unitaria estacional (HEGY)
ARIMAX/SARIMAX	de N_t tras remover $\beta'x_t$	de N_t	residuales de regresión aún autocorrelacionados con evento conocido

Estacionariedad: ADF rechaza + KPSS no rechaza $\Rightarrow$ estacionaria. ADF no rechaza + KPSS rechaza $\Rightarrow$ diferenciar. **Sobre-diferenciación:** pico negativo fuerte y aislado en rezago 1 tras diferenciar $\Rightarrow$ reducir d .

2. Estimación

Método	Cuándo usarlo	Fórmula clave
Momentos / MCO	Valores iniciales; MCO suficiente si es AR puro	Yule-Walker: $\rho(k) = \sum \phi_i \rho(k-i)$
MLE	Estándar general, necesario si hay MA	$\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, I(\theta_0)^{-1})$
Selección de modelo	Menor IC entre candidatos válidos	$AIC = -2 \log L + 2k$; $BIC = -2 \log L + k \log n$; $AICc = AIC + \frac{2k(k+1)}{n-k-1}$

AIC: mejor para predicción. BIC: mejor para parsimonia/inferencia (n grande). AICc: preferible con n pequeño. **Chequeo de sobreajuste:** agregar un parámetro extra ($p+1$ o $q+1$); si no es significativo, confirma el modelo elegido.

3. Validación (residuales)

Supuesto	Prueba	Si falla	Acción
Media cero	prueba t	sesgo sistemático	falta constante/tendencia; re-especificar
No correlación	Ljung-Box	estructura no capturada	aumentar p/q
Homoscedasticidad	ARCH-LM, Breusch-Pagan	varianza no constante	GARCH o transformar (log/Box-Cox)
Normalidad	Jarque-Bera, Shapiro-Wilk	colas pesadas/asimetría	usar bootstrap para inferencia

Bootstrap: clásico (residuos) si el modelo está bien especificado; AR-sieve si hay dudas sobre la forma/orden correcto del modelo.


4. Uso del modelo

Incertidumbre total = **aleatoria** (irreducible, del proceso) + **epistémica** (reducible, de estimar θ con datos finitos). Mejor predictor (MMSE): $\hat{Y}_{t+h|t} = E[Y_{t+h}|\mathcal{F}_t]$; para $h \rightarrow \infty$ converge a μ (media incondicional). **Winkler score** evalúa intervalos: penaliza ancho y no-cobertura; menor es mejor. Validar siempre **fuera de muestra** (RMSE/MAE/Winkler), no solo con IC dentro de muestra.

5. Complementos prácticos

Atípicos: AO (puntual), IO (se disipa), LS (nivel permanente), TC (transitorio) $\rightarrow$ dummies. Auto-selección (**auto.arima**) solo como punto de partida, confirmar manualmente. Monitorear en producción: CUSUM sobre errores de pronóstico; cambios grandes en parámetros $\rightarrow$ re-especificar, no solo re-estimar.

4 Árbol de decisión integral



Regla maestra: en cada rombo de decisión, la ruta roja (recuadros rojos) siempre implica volver a un paso *anterior* del árbol —nunca se "parcha" el problema únicamente ajustando la fase de uso. Solo se llega al nodo verde final cuando el modelo superó identificación, estimación, *todos* los diagnósticos residuales relevantes y la validación fuera de muestra frente a un benchmark razonable.