UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

Diseño y Desarrollo de Encuestas

Giovany Babativa-Márquez, PhD
jgbabativam@unal.edu.co

Contenido

- Tipos de investigación: **no experimental**, **experimental** y **cuasiexperimental**
- El impacto como indicador de una política pública
- Contrafactual, receta e indicador de impacto
- Métodos: experimento aleatorio, **diferencias simples**, **diferencias en diferencias**, **regresión discontinua** y **emparejamiento (PSM)**
- El tamaño de muestra y el **efecto de diseño**

Fuentes: Gertler et al. (2017); Angrist y Pischke (2009); Imbens y Rubin (2015); Duflo et al. (2007); Gutiérrez (2020).

UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

Tipos de investigación

Tres tipos de investigación

Se distinguen por **dos** preguntas: ¿el investigador **interviene** (manipula la causa)? y ¿asigna esa intervención **al azar**?

No experimental (observacional). Se observan y miden las características de la población **tal como son**, sin intervenir. Describe y estima (niveles, distribuciones, asociaciones), pero las relaciones causales quedan expuestas a la **confusión**.

Experimental. El investigador **aplica** la intervención y la **asigna al azar** entre las unidades: grupo tratamiento y grupo control comparables por construcción.

Cuasiexperimental. Hay una intervención y un grupo de comparación, pero la asignación **no es aleatoria** (la decide el programa, una regla o el propio participante): el contrafactual se construye con supuestos.

La encuesta no experimental

Es el caso más común en las oficinas de estadística: GEIH, ECV, censos.

- **Objetivo**: describir a la población con **validez externa** (inferencia de la muestra probabilística a la población).
- **Transversal** (una medición) o **longitudinal** (panel: las mismas unidades en el tiempo).
- Permite **asociaciones** (p. ej., pobreza y educación del jefe), pero no atribuir causalidad: hay variables omitidas, causalidad inversa y selección.

> **Ejemplo.** Con la ECV se podría observar que los hogares que reciben un subsidio son más pobres que los que no lo reciben. ¿El subsidio genera pobreza? No: el programa **selecciona** a los hogares pobres.

El diseño experimental

Elementos: intervención controlada, **asignación aleatoria**, grupo **control** y medición **antes y después** (línea de base y seguimiento).

- Máxima **validez interna**: la diferencia entre grupos se atribuye a la intervención.
- Limitaciones: costo, ética (no se puede negar un beneficio esencial), contaminación entre grupos y validez externa (el piloto no siempre se replica a escala).

> **Experimentos en las encuestas.** Las ONE también experimentan con la **propia encuesta**: versiones del cuestionario, modos de recolección o incentivos asignados al azar entre submuestras (*split-ballot*), para medir su efecto en la respuesta y en las estimaciones.

El diseño cuasiexperimental

La intervención **ya existe** o no puede aleatorizarse: se busca un grupo de comparación **lo más parecido posible** al tratado.

	No experimental	**Experimental**	**Cuasiexperimental**
¿Hay intervención?	No	Sí, del investigador	Sí, del programa
Asignación	—	Aleatoria	No aleatoria (regla, elección)
Grupo de comparación	No necesariamente	Control aleatorio	Construido
Fortaleza	Validez externa	Validez interna	Viabilidad
Métodos	Estimación por muestreo	Diferencia de medias, regresión	DiD, RD, PSM

Los métodos cuasiexperimentales se desarrollan en la sección **Métodos de evaluación**.

UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

Evaluación de impacto

El impacto como indicador de una política pública



Definición de impacto

Es un **efecto causal** de una intervención sobre una población objetivo.

Este efecto hace que el comportamiento estructural de la población cambie en el mediano (largo) plazo y este cambio es atribuible específicamente a la intervención y no a otros factores que pueden influir en la población durante el periodo en que se realiza la intervención.

Subsidios de familias en acción

Los resultados del estudio pueden arrojar índices más altos en términos de calidad de vida en el subgrupo de personas que recibieron el subsidio, pero esto puede no deberse a la intervención per se, sino, por ejemplo, a la recuperación general de la economía en ese periodo de tiempo.

¿Por qué evaluar el impacto?

Una evaluación es un proceso objetivo de entendimiento acerca de cómo fue implementada una intervención, qué efectos tuvo, para quiénes, dónde y por qué.

¿Por qué evaluar? → Existen muchas razones.

- No evaluar una política es inadecuado porque significaría que no se podría proveer ningún tipo de evidencia significativa que apoye cualquier afirmación que se quiera realizar acerca de la efectividad de la intervención.
- Es importante evaluar el impacto de las intervenciones para tomar las siguientes decisiones: continuarlas, eliminarlas o mejorarlas.
  - Si una intervención no tiene impacto, no deberían gastarse esfuerzos económicos y logísticos en su continuidad.
  - Si una intervención sí tiene impacto, se debería dar continuidad a la política que generó la intervención y, si es posible, mejorarla.

Ejemplo: Programa de Alimentación Escolar (PAE)

El PAE entrega un complemento alimentario (desayuno, refrigerio o almuerzo) a los estudiantes de los colegios **oficiales** durante la jornada escolar. Hoy lo orienta la Unidad de Alimentos para Aprender (UApA).

- **Población objetivo:** niños, niñas y adolescentes matriculados en el sector oficial.
- **Intervención:** ración diaria en el colegio durante el calendario escolar.
- **Impactos esperados:** mayor **asistencia** y **permanencia** (menos deserción), mejor estado **nutricional** y mejor **rendimiento** académico.
- **Pregunta:** ¿los estudiantes que reciben el PAE asisten más y desertan menos **por** el programa, o porque sus colegios y hogares ya eran distintos?

Segundo ejemplo: Ser Pilo Paga

Programa del Gobierno nacional (2014-2018): **crédito condonable** para que bachilleres de bajos ingresos y alto desempeño estudiaran en universidades **acreditadas de alta calidad**.

- **Elegibilidad:** puntaje del examen **Saber 11** por encima de un mínimo **y** puntaje del **SISBÉN** por debajo de un corte.
- **Impactos esperados:** acceso a la educación superior, matrícula en universidades de calidad, graduación e ingresos futuros.

Un cuasiexperimento natural. La elegibilidad depende de **umbrales**: los estudiantes justo por encima y justo por debajo del puntaje mínimo son casi idénticos. Es el escenario de la **regresión discontinua** (Londoño-Vélez et al. 2020).

Preguntas

Si se habla de una evaluación de impacto, existe una pregunta importante que debe ser contestada:

¿Cuál habría sido la situación si la intervención no se hubiese realizado?

Es posible simular una realidad similar mediante la definición de un grupo contrafactual - que está conformado por individuos que no participan de la intervención - y contrastarlo con el grupo de participantes que sí recibieron la intervención.

Contrafactual: todo acontecimiento o toda situación que no ha acontecido en el universo actualmente observable por la investigación humana, pero que pudiera haber ocurrido.



Receta para evaluar el impacto

Ingredientes:

- **Una intervención:** generada por una política o unas directrices de alguna institución.
- **Dos grupos:** un grupo es el que recibe la intervención (grupo tratamiento) y un grupo que no recibe la intervención (grupo control).
- **Dos tiempos:** en el primer tiempo (línea de base) ningún grupo ha recibido la intervención y en el segundo tiempo (seguimiento) el grupo tratamiento ya ha recibido la intervención.



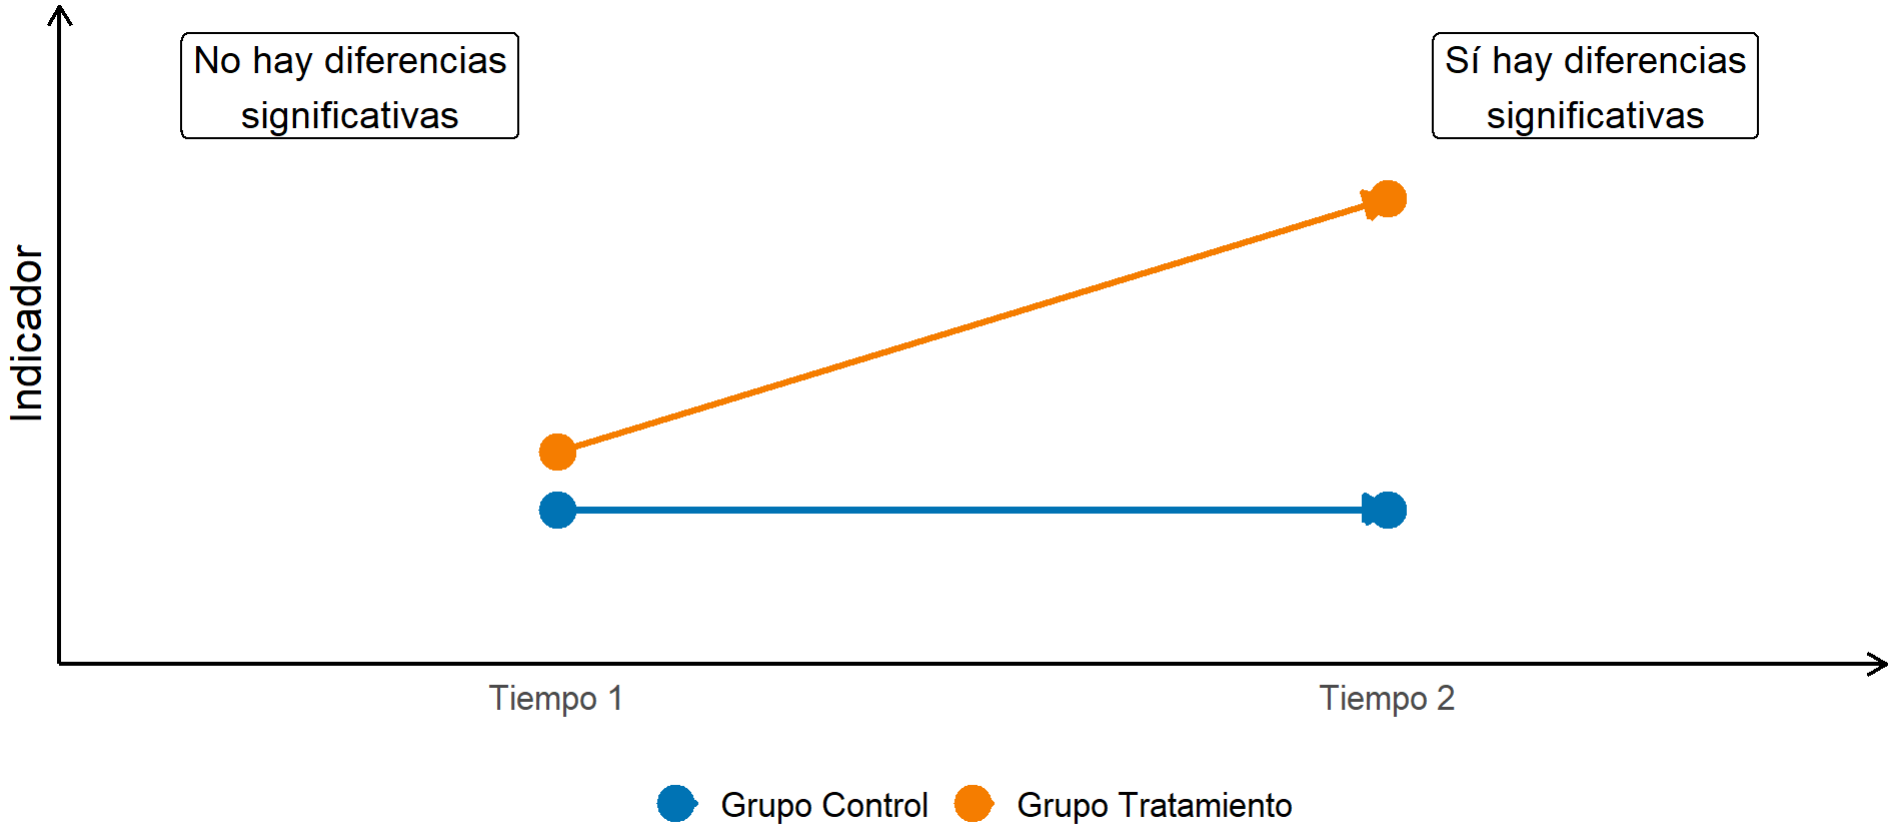
Procedimiento: realice la medición de la línea de base en los dos grupos antes de realizar la intervención. Espere un tiempo prudente antes de realizar la segunda medición.

Receta para evaluar el impacto

UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

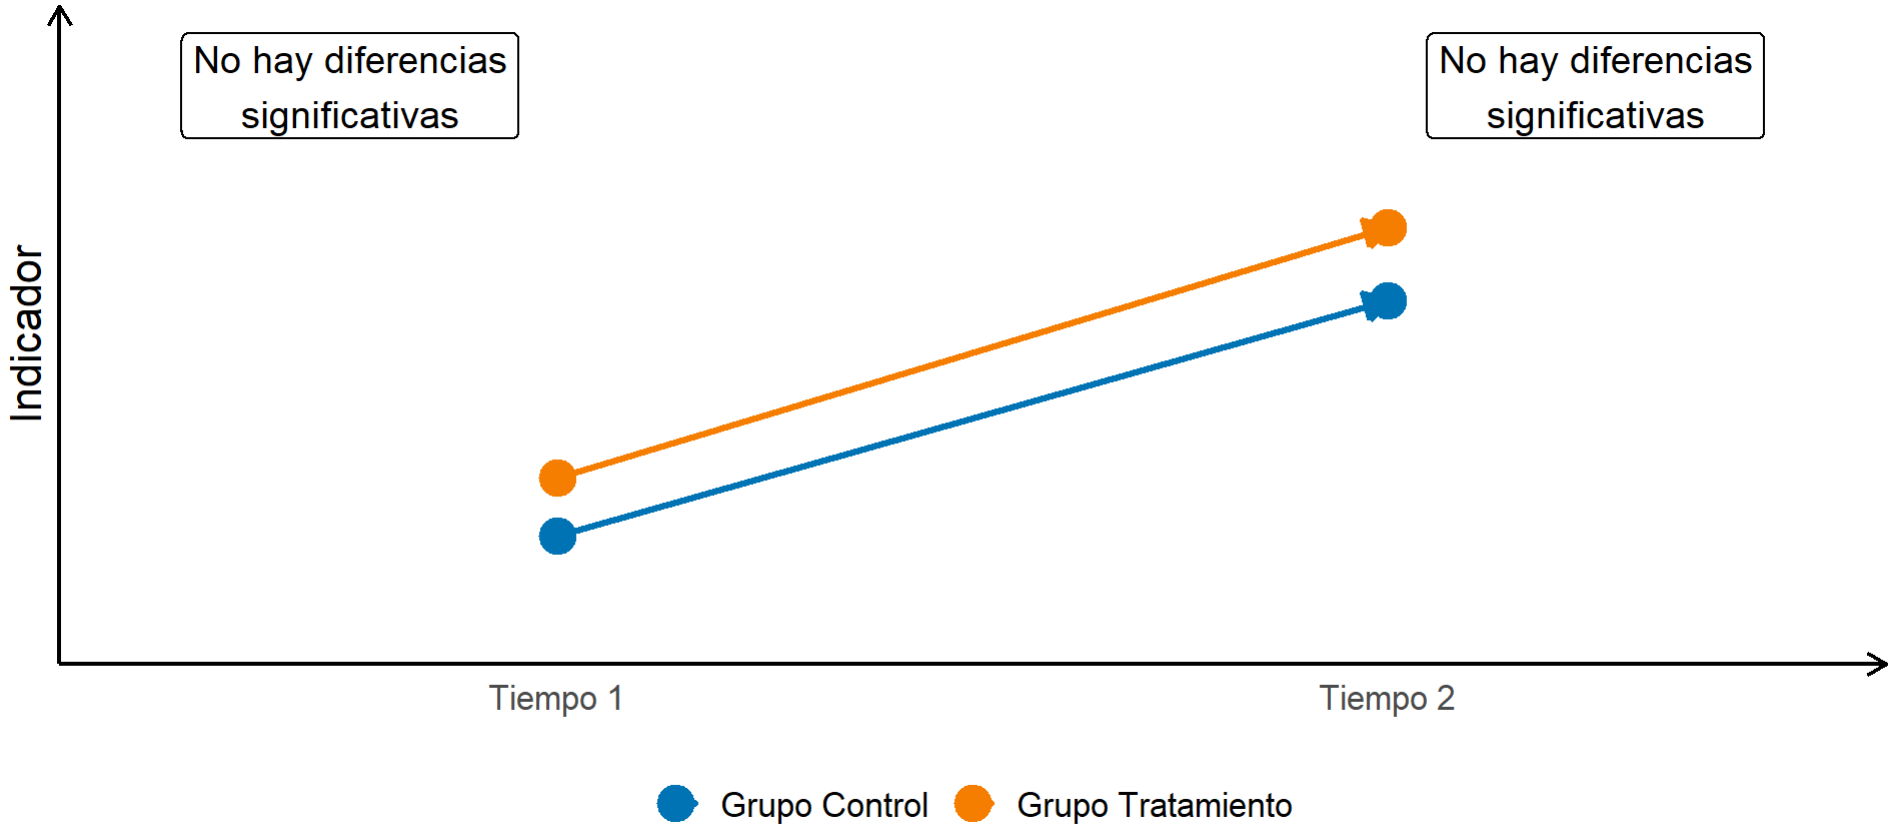
- Nótese que la intervención se efectúa **entre el primer y el segundo tiempo**. Además se espera que en el primer tiempo no existan diferencias significativas entre grupos. De lo contrario se pone en tela de juicio la idoneidad del grupo control.
- Lo ideal es **aleatorizar** los grupos desde antes de intervenir.
- Sin embargo, es muy común que la intervención ya se haya recibido antes de la realización de la encuesta. Cuando esto sucede, se debe recurrir a técnicas de emparejamiento (propensity score matching, etc.) para seleccionar un grupo contrafactual similar estructuralmente al grupo intervenido. Ej.: programas de empleo del DPS.
- Más aún, es posible crear varios grupos controles, que sean significativamente diferentes al momento de levantar la línea de base. Ej.: nutrición en la primera infancia con estratos altos.
- El grupo control debe tener un tamaño significativamente mayor pues es muy común que, en intervenciones estatales, los controles se vuelvan paulatinamente tratamientos. Ej.: víctimas que son reparadas paulatinamente.

Impacto gráfico



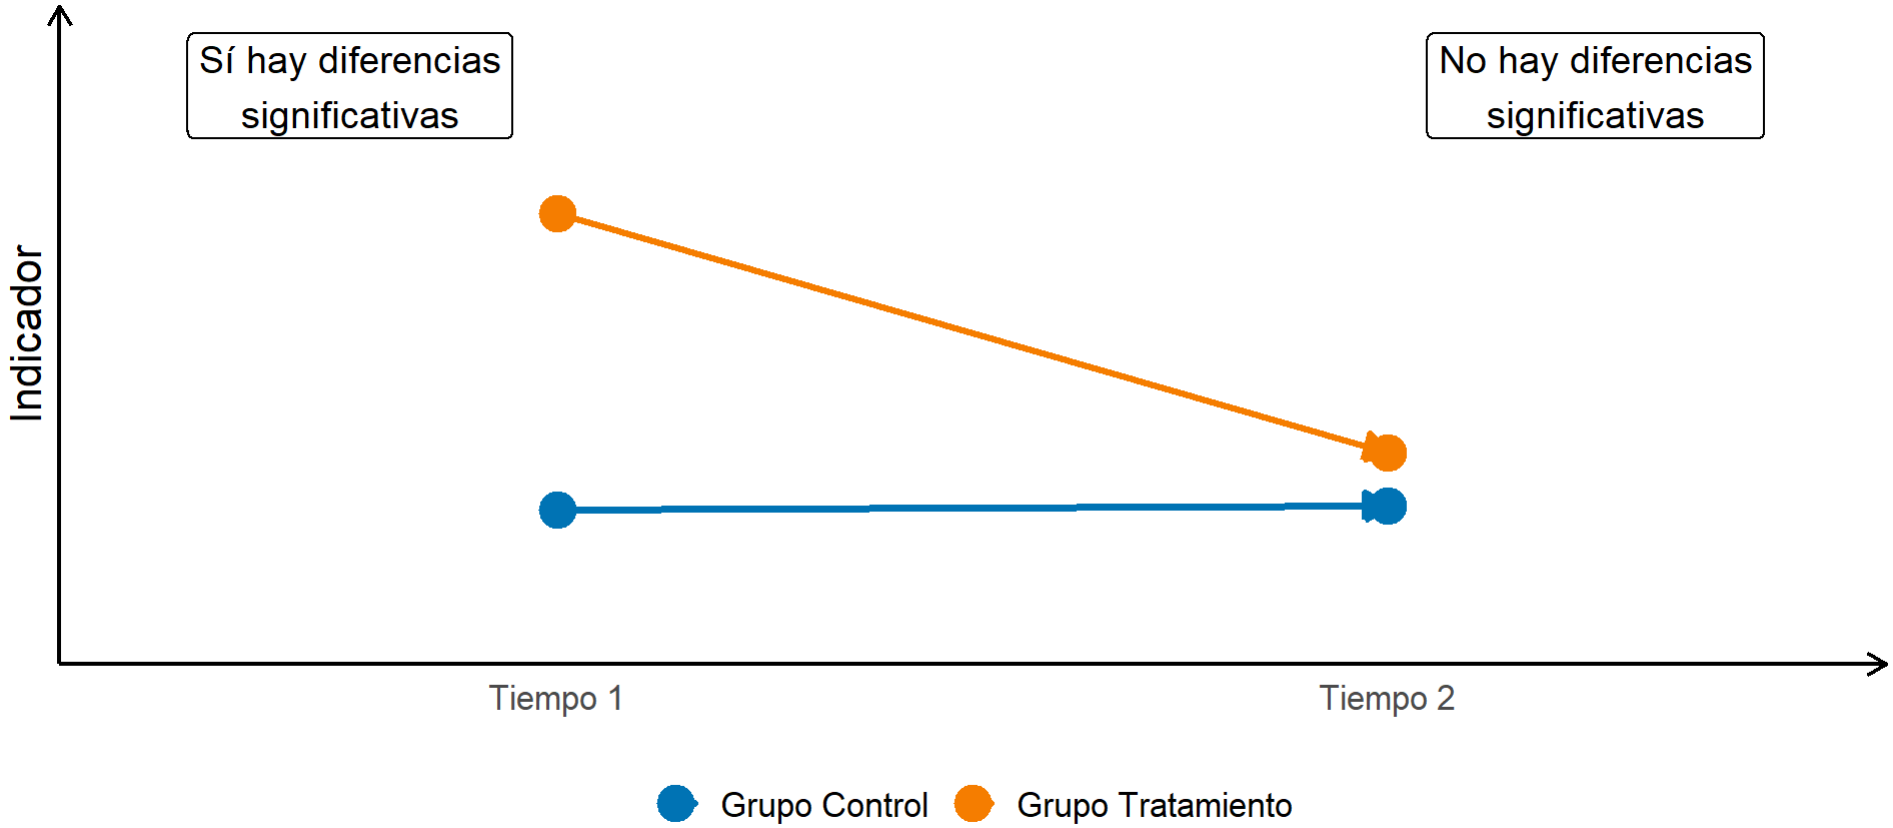
Sí hay IMPACTO positivo

Impacto gráfico



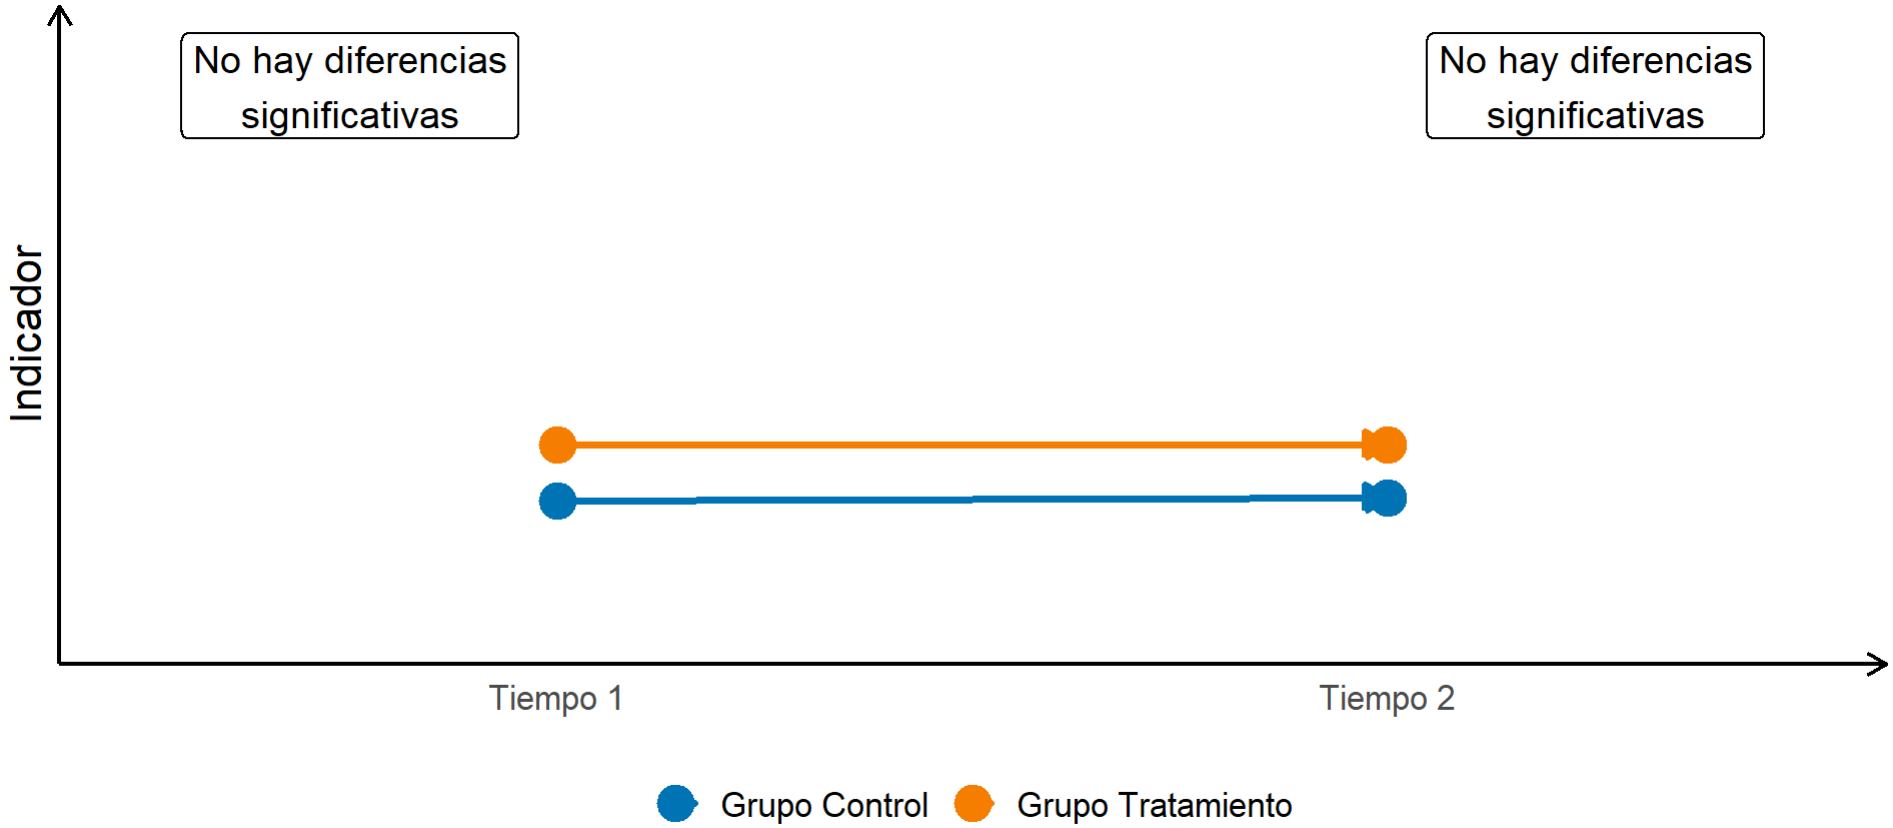
No existe IMPACTO

Impacto gráfico



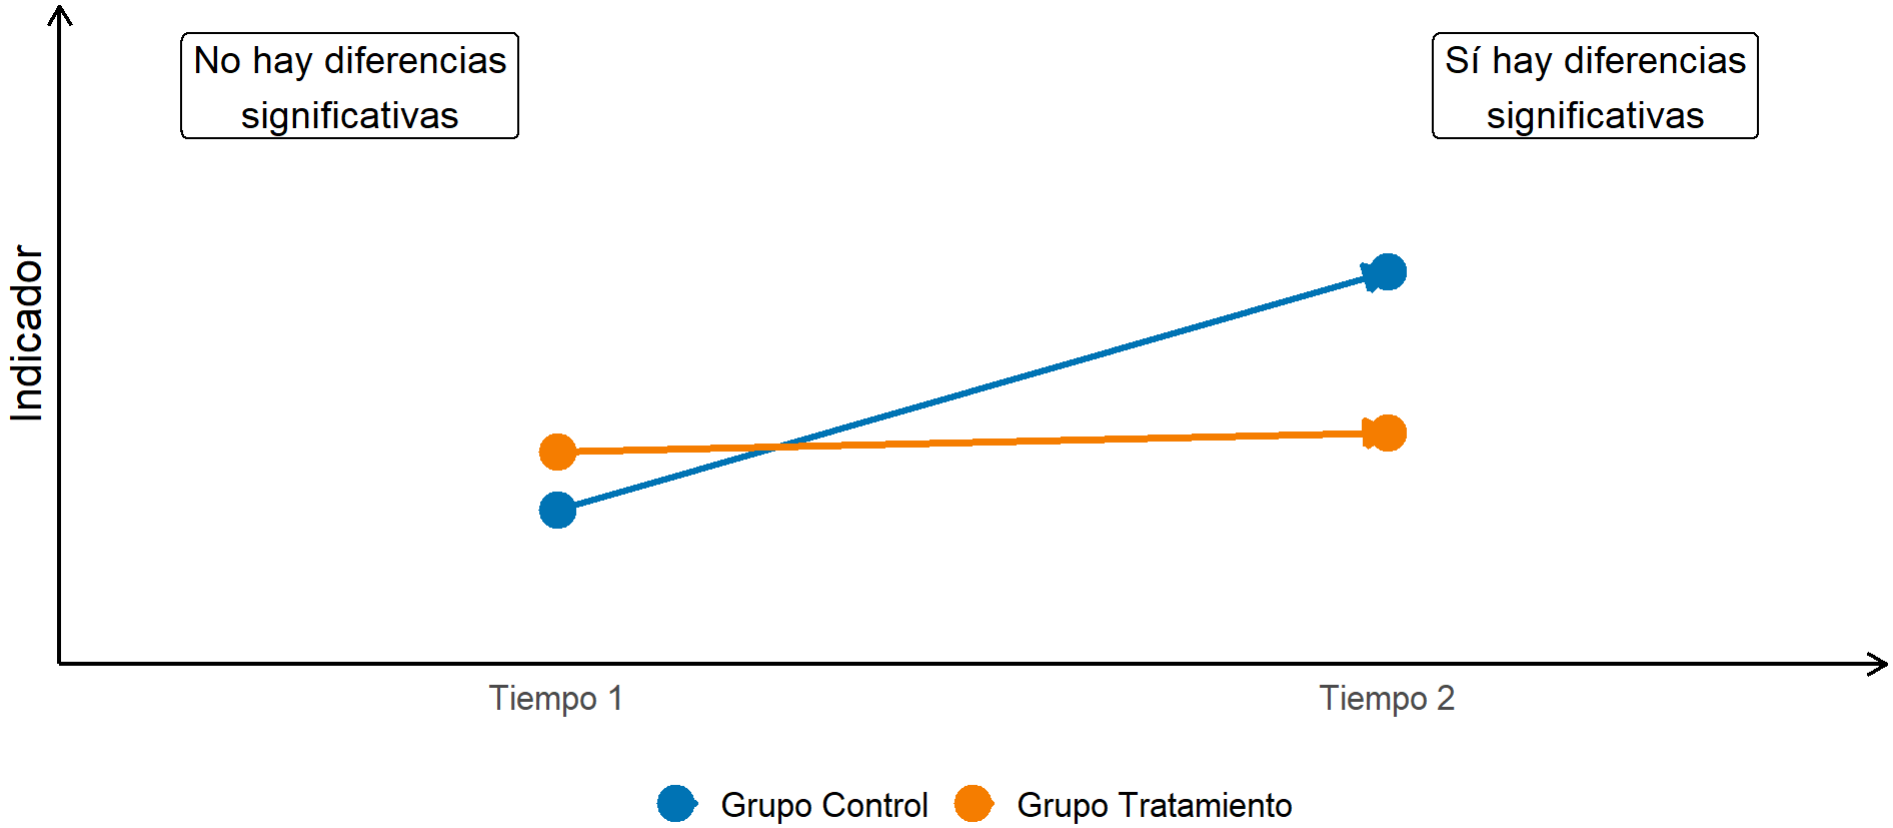
Sí hay IMPACTO negativo

Impacto gráfico



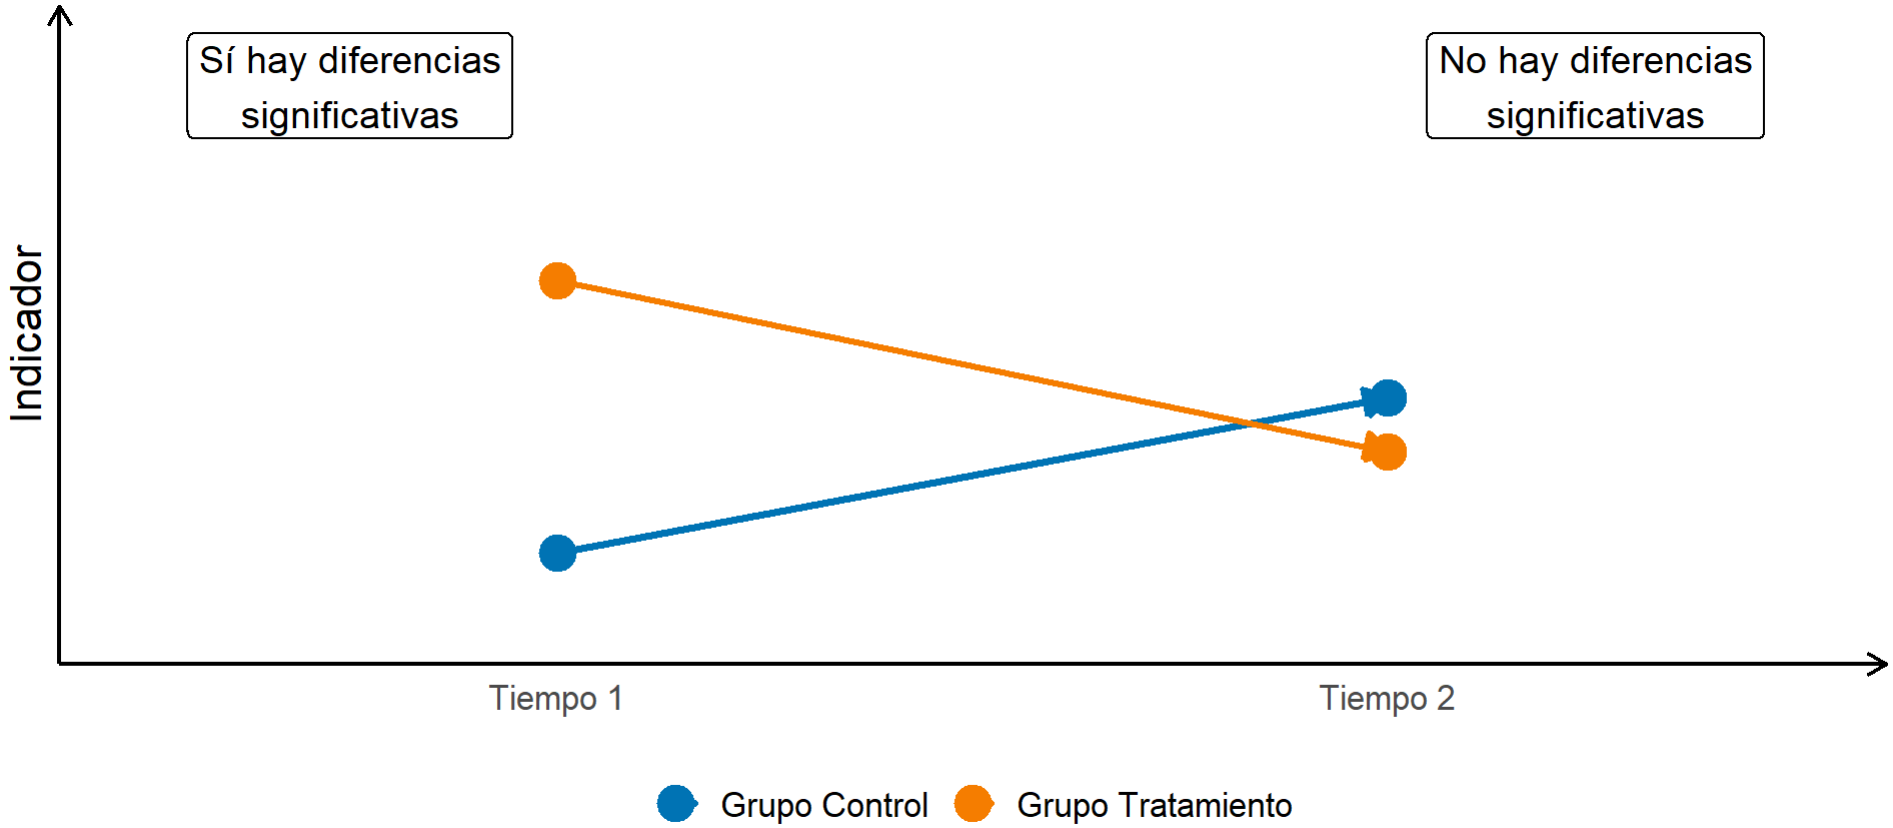
No hay IMPACTO

Impacto gráfico



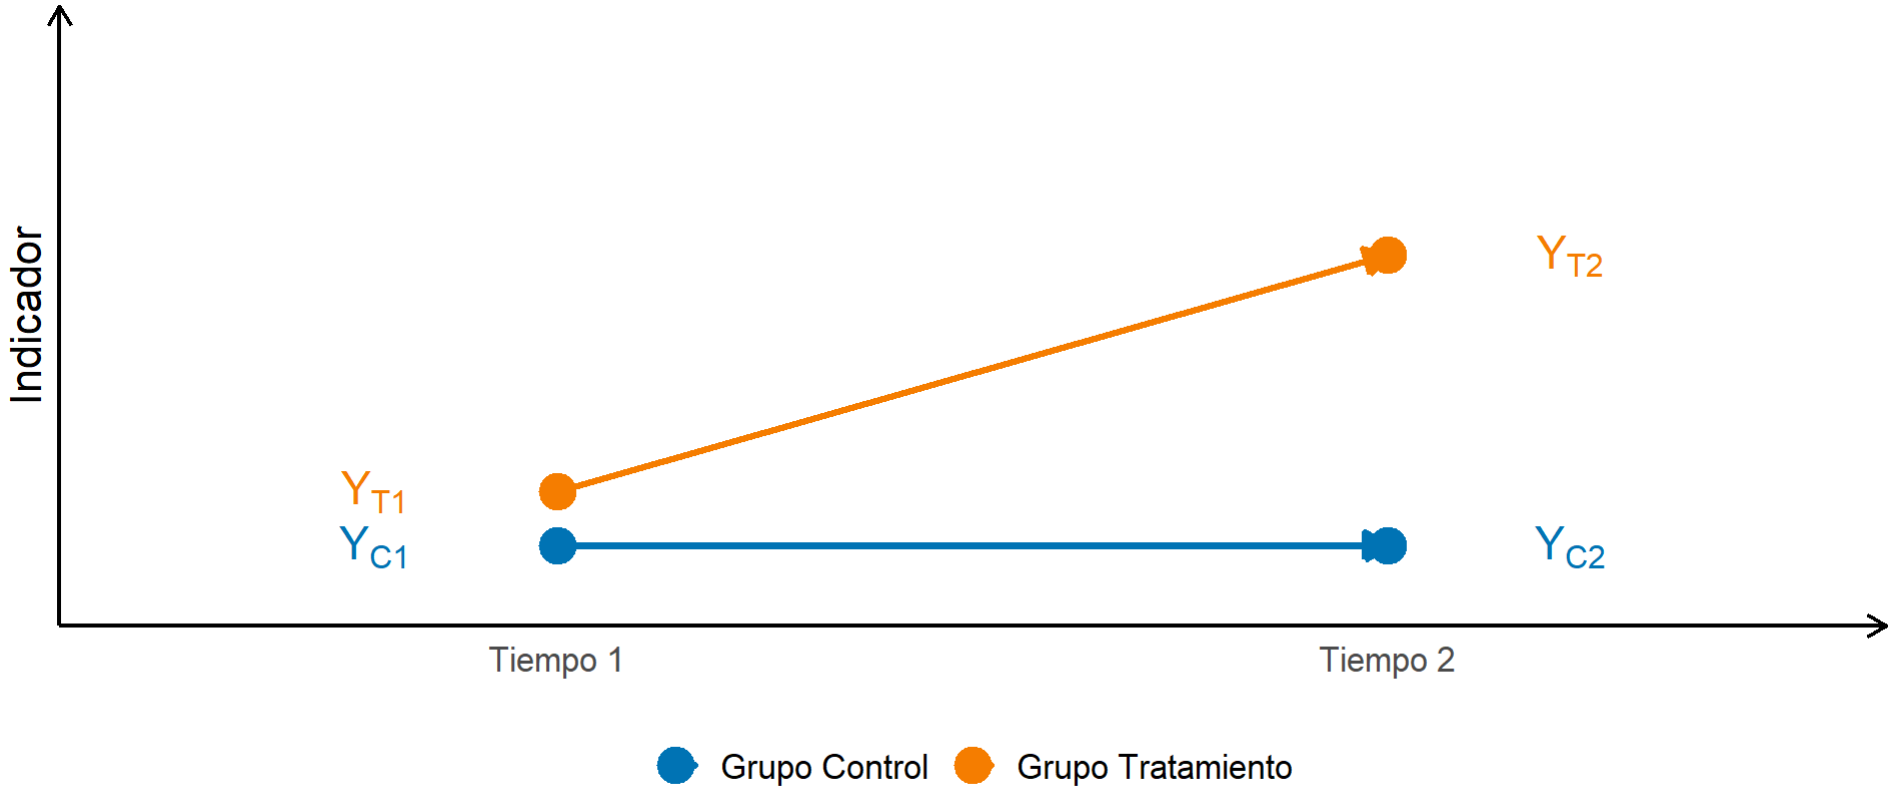
Sí hay IMPACTO negativo

Impacto gráfico



Sí hay IMPACTO negativo

Indicador de Impacto



$$\text{IMPACTO} = (Y_{T2} - Y_{T1}) - (Y_{C2} - Y_{C1})$$

UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

Métodos de evaluación

Resultados potenciales

Cada unidad i tiene dos resultados potenciales: $Y_i(1)$ con tratamiento y $Y_i(0)$ sin él, sólo se observa uno (Imbens y Rubin 2015):

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0), \qquad D_i \in \{0, 1\}$$

Parámetros. $ATE = E[Y(1) - Y(0)]$ (efecto promedio) y $ATT = E[Y(1) - Y(0) \mid D = 1]$ (efecto sobre los tratados).

La comparación ingenua mezcla el efecto con el **sesgo de selección**:

$$\underbrace{E[Y \mid D = 1] - E[Y \mid D = 0]}_{\text{diferencia observada}} = ATT + \underbrace{E[Y(0) \mid D = 1] - E[Y(0) \mid D = 0]}_{\text{sesgo}}$$

Cada método busca un **contrafactual creíble** para $E[Y(0) \mid D = 1]$.

Experimento aleatorio

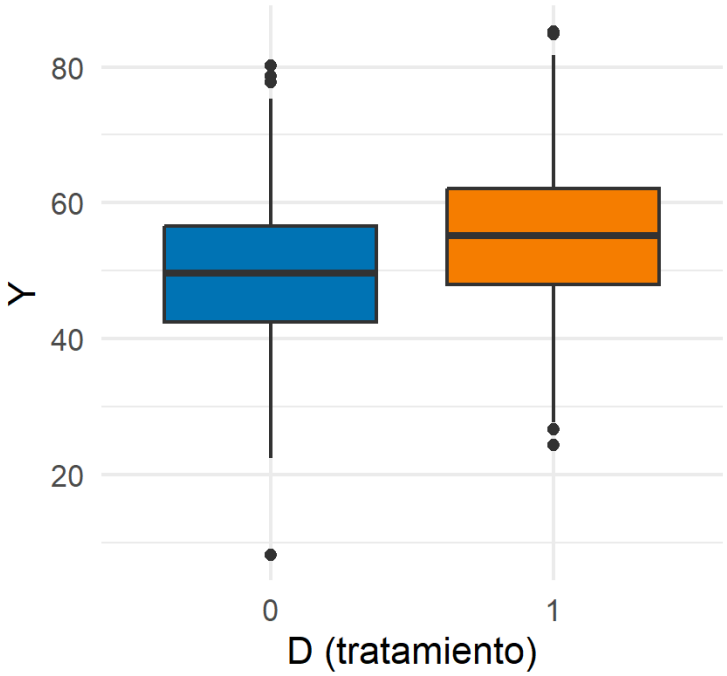
Si D se asigna **al azar**, el sesgo de selección es cero en esperanza:

$$Y_i = \alpha + \tau D_i + \boldsymbol{x}_i'\boldsymbol{\beta} + \varepsilon_i, \qquad \hat{\tau} = \bar{y}_T - \bar{y}_C$$

Las covariables $\boldsymbol{x}_i$ no son necesarias, pero **reducen la varianza** (Duflo et al. 2007).

```r
set.seed(1)
rct <- tibble(x = rnorm(1000, 50, 10),
              D = rbinom(1000, 1, 0.5),
              y = 20 + 0.6 * x + 5 * D +
                  rnorm(1000, 0, 8))
rbind(
  sin_x = coef(summary(lm(y ~ D, rct)))["D", 1:2],
  con_x = coef(summary(lm(y ~ D + x, rct)))["D", 1:2])
```

```
      Estimate Std. Error
sin_x 5.504373  0.6686319
con_x 4.951900  0.5344171
```



Diferencias simples

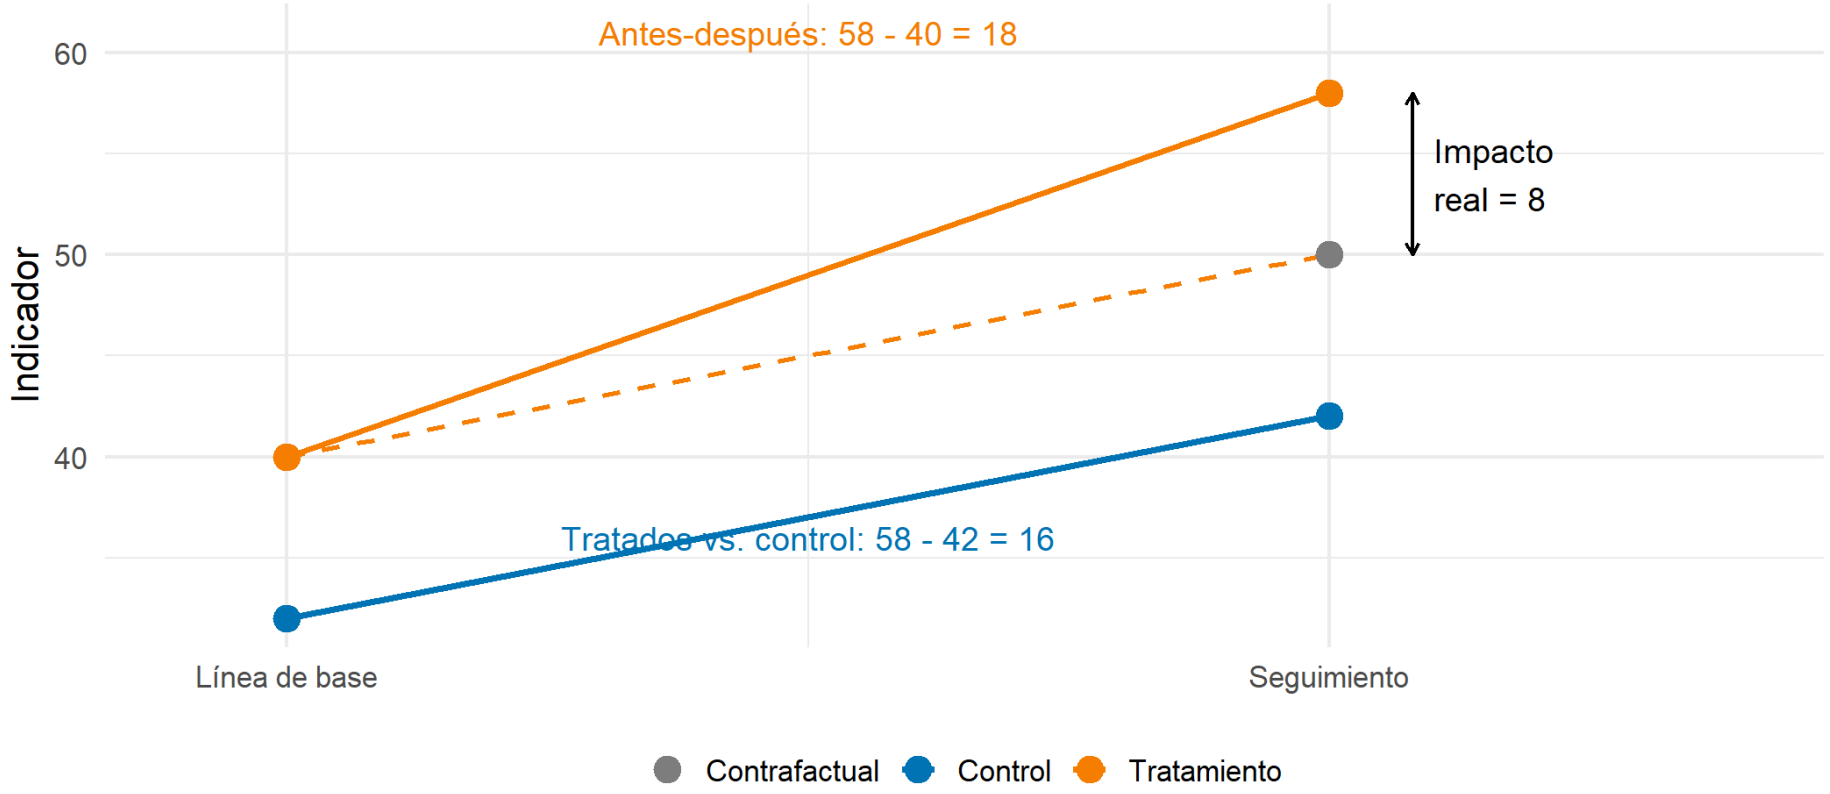
Con **una sola** comparación se obtienen dos estimadores habituales, ambos sesgados si no hay aleatorización:

Antes-después (solo tratados): $\hat{\tau} = \bar{y}_{T2} - \bar{y}_{T1}$. Supone que **sin** la intervención no habría habido cambio: confunde el impacto con la **tendencia**.

Tratados vs. no tratados (después): $\hat{\tau} = \bar{y}_{T2} - \bar{y}_{C2}$. Supone que los grupos eran iguales: confunde el impacto con la **selección**.

En regresión: $Y_i = \alpha + \tau D_i + \varepsilon_i$ con datos de corte transversal; τ es causal solo si D es independiente de ε.

Las diferencias simples en un gráfico



Ambas diferencias **sobrestiman** el impacto: la tendencia (+10) y la brecha inicial (+8) se atribuyen a la intervención.

Diferencias en diferencias (DiD)

Combina las dos diferencias simples (el indicador de impacto de la lámina anterior) en un modelo con datos de **panel** o cortes repetidos (Angrist y Pischke 2009):

$$Y_{it} = \beta_0 + \beta_1 T_i + \beta_2 Post_t + \tau\left(T_i \times Post_t\right) + \boldsymbol{x}_{it}'\boldsymbol{\gamma} + \varepsilon_{it}$$

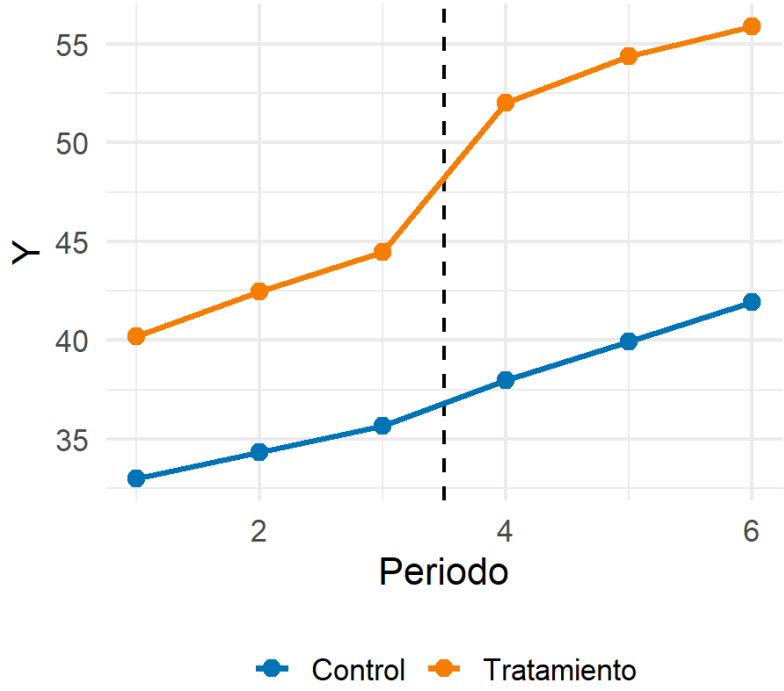
- T_i: grupo tratamiento; $Post_t$: periodo de seguimiento.
- $\tau = (Y_{T2} - Y_{T1}) - (Y_{C2} - Y_{C1})$: el **impacto**.

Supuesto clave: tendencias paralelas. Sin la intervención, ambos grupos habrían evolucionado igual. Se verifica con **varios periodos antes** de la intervención.

DiD en R

```r
set.seed(2)
panel <- expand_grid(id = 1:400, t = 1:6) |>
  mutate(T = as.integer(id <= 200),
         post = as.integer(t >= 4),
         y = 30 + 8 * T + 2 * t +
             6 * T * post +
             rnorm(n(), 0, 4))
fit <- lm(y ~ T * post, panel)
coef(summary(fit))["T:post", 1:2]
```

```
 Estimate Std. Error
6.1367738  0.3519624
```



Antes de la intervención (periodos 1-3) las tendencias son **paralelas**; después, la brecha crece en $\tau = 6$ (valor verdadero de la simulación).

Regresión discontinua (RD)

La elegibilidad depende de un **puntaje** x y un **umbral** c (p. ej., SISBÉN): $D_i = 1(x_i \leq c)$. Cerca del umbral, los hogares son comparables (Imbens y Lemieux 2008):

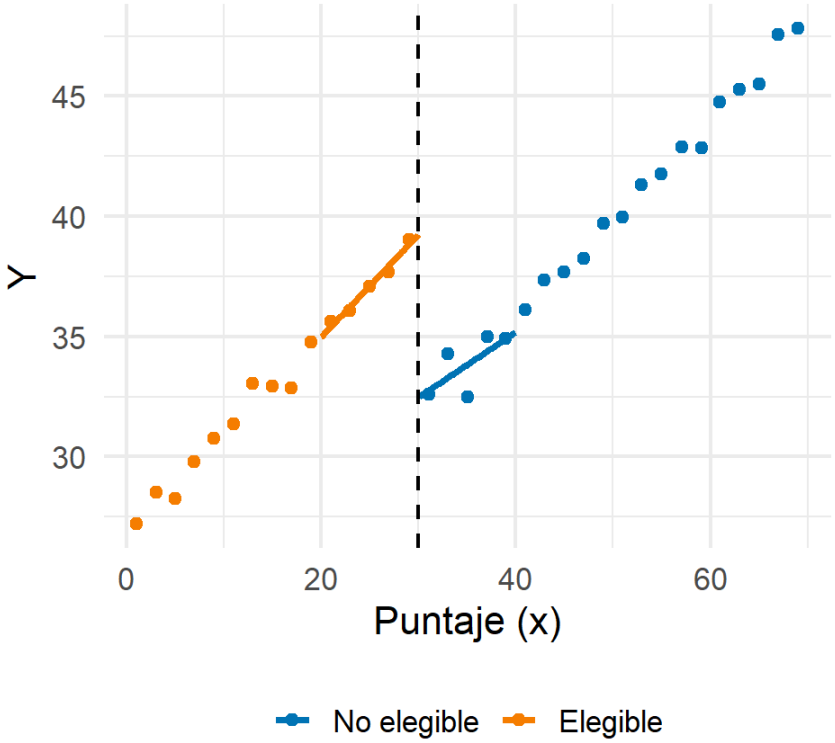
$$Y_i = \alpha + \tau D_i + \beta_1 (x_i - c) + \beta_2 D_i (x_i - c) + \varepsilon_i, \qquad |x_i - c| \leq h$$

- τ: salto en el umbral = efecto **local** (para quienes están cerca de c).
- h: ancho de banda; menor sesgo con h pequeño, menor varianza con h grande.
- **Nítida** (todos los elegibles reciben) vs. **difusa** (la probabilidad de recibir salta en c).
- Supuesto: los hogares **no manipulan** su puntaje (revisar la densidad de x alrededor de c).

RD en R

```r
set.seed(3)
c0 <- 30; h <- 10          # umbral y ancho
rd <- tibble(x = runif(2000, 0, 70),
             D = as.integer(x <= c0),
             y = 20 + 0.4 * x + 7 * D +
                 rnorm(2000, 0, 4))
local <- filter(rd, abs(x - c0) <= h)
fit <- lm(y ~ D * I(x - c0), local)
coef(summary(fit))["D", 1:2]
```

```
 Estimate Std. Error
6.7787812  0.7297743
```



El salto estimado se compara con el verdadero $\tau = 7$. En la práctica: `rdrobust` (ancho de banda óptimo) y `rddensity` (prueba de manipulación).

Emparejamiento por puntaje de propensión (PSM)

Cuando la intervención **ya ocurrió** y no fue aleatoria, se busca para cada tratado un control con características similares (Rosenbaum y Rubin 1983):

$$e(\boldsymbol{x}) = P(D = 1 \mid \boldsymbol{x}), \qquad \log \frac{e(\boldsymbol{x})}{1 - e(\boldsymbol{x})} = \boldsymbol{x}'\boldsymbol{\beta}$$

[Math Processing Error] $j(i)$: el control más parecido a i, con $e(\boldsymbol{x}_j) \approx e(\boldsymbol{x}_i)$.

Supuestos. (1) **Independencia condicional**: dado $\boldsymbol{x}$, la participación no depende de $Y(0)$ — solo se controla lo **observable**. (2) **Soporte común**: $0 < e(\boldsymbol{x}) < 1$.

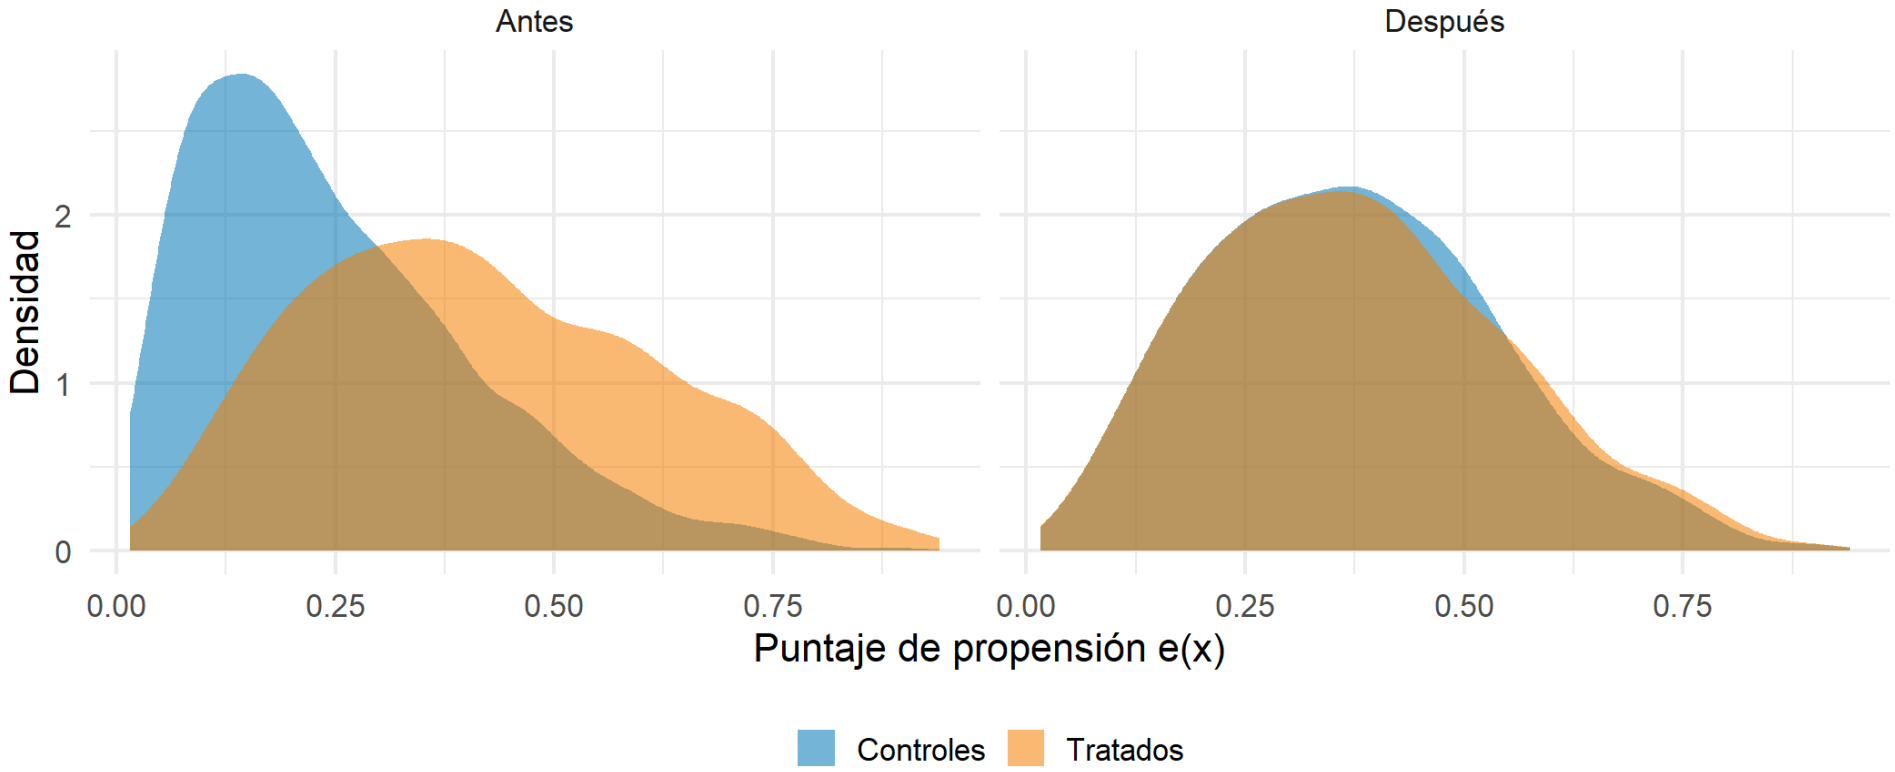
PSM en R con `MatchIt`

```r
library(MatchIt)
set.seed(4)
obs <- tibble(educ = rnorm(3000, 9, 3), ingreso = rlnorm(3000, 13.5, 0.6),
              rural = rbinom(3000, 1, 0.3)) |>
  mutate(D = rbinom(n(), 1, plogis(1 - 0.25 * educ - 0.6 * scale(log(ingreso))[, 1] +
                                     0.8 * rural)),
         y = 40 + 2 * educ + 3 * scale(log(ingreso))[, 1] - 4 * rural + 5 * D +
             rnorm(n(), 0, 6))
m <- matchit(D ~ educ + log(ingreso) + rural, data = obs, method = "nearest",
             distance = "glm", caliper = 0.1)
emp <- match.data(m)
c(ingenua = unname(coef(lm(y ~ D, obs))["D"]),
  PSM = unname(coef(lm(y ~ D, emp, weights = weights))["D"]))   # verdadero: 5
```

```
   ingenua        PSM
-0.6790042  5.3020051
```

Los tratados tienen menos educación e ingreso, que también bajan Y: la comparación ingenua **esconde** el efecto. Después del emparejamiento se recupera $\tau \approx 5$. Se revisa el balance con `summary(m)` o `cobalt::love.plot(m)`.

El balance antes y después del emparejamiento



Antes, los tratados tienen puntajes mucho más altos; después del emparejamiento las distribuciones **coinciden** (Ho et al. 2011).

¿Qué método usar?

Método	Supuesto clave	Datos	Estimador
Experimento aleatorio	Asignación al azar	Seguimiento (línea de base deseable)	$\bar{y}_T - \bar{y}_C$
Antes-después	Sin tendencia	Tratados, dos tiempos	$\bar{y}_{T2} - \bar{y}_{T1}$
Tratados vs. no tratados	Sin selección	Seguimiento	$\bar{y}_{T2} - \bar{y}_{C2}$
Diferencias en diferencias	Tendencias paralelas	Panel o cortes repetidos	τ de $T \times Post$
Regresión discontinua	Sin manipulación del puntaje	Puntaje y umbral	Salto en c
PSM	Independencia condicional y soporte común	Muchas covariables previas	ATT emparejado

Se combinan con frecuencia (p. ej., **PSM + DiD**). Otros: variables instrumentales y control sintético (Gertler et al. 2017).

UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

Tamaño de muestra y efecto de diseño

El diseño no siempre es de elementos

Clave. En las evaluaciones con encuestas, el tratamiento y la muestra suelen asignarse por **conglomerados** (municipios, colegios, UPM, manzanas), no por hogares: la varianza crece en el **efecto de diseño**

$$DEFF \approx 1 + (\bar{m} - 1)\rho_y$$

$\bar{m}$: unidades por conglomerado; ρ_y: correlación intraclase. Ignorarlo **subestima** los errores estándar y el tamaño de muestra.

- Las fórmulas para comparar grupos se multiplican por el $DEFF$.
- Los errores estándar se calculan con el **diseño**: `survey::svyglm()` con `ids = ~conglomerado`, estratos y pesos.

Aleatorizar por conglomerados

40 colegios (20 tratados), 25 estudiantes por colegio, $\rho_y \approx 0{,}2$:

```r
library(survey)
set.seed(5)
col <- tibble(colegio = 1:40, D = rep(0:1, 20), u = rnorm(40, 0, 2.5))
est <- col |> slice(rep(1:40, each = 25)) |>
  mutate(y = 50 + 2 * D + u + rnorm(n(), 0, 5))
tau <- coef(lm(y ~ D, est))["D"]
ee_mas <- coef(summary(lm(y ~ D, est)))["D", 2]           # como si fuera M.A.S
dis <- svydesign(ids = ~colegio, data = est)
ee_dis <- SE(svyglm(y ~ D, dis))["D"]
round(c(tau = unname(tau), EE_MAS = ee_mas, EE_diseno = unname(ee_dis),
        DEFF = unname((ee_dis / ee_mas)^2),
        DEFF_teorico = 1 + (25 - 1) * 2.5^2 / (2.5^2 + 5^2)), 2)
```

```
       tau       EE_MAS    EE_diseno         DEFF DEFF_teorico
      1.59         0.37         1.00         7.39         5.80
```

El estadístico t pasa de 4.3 (como si fuera M.A.S) a 1.6 con el diseño: ignorar los conglomerados **exagera** la significancia.

Tamaño de muestra (adelanto)

Para comparar dos proporciones con significancia α y potencia $1-\beta$, **por grupo:**

$$n = DEFF \, \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 \, [P_1(1-P_1) + P_2(1-P_2)]}{(P_1 - P_2)^2}$$

```r
library(samplesize4surveys)
P1 <- 0.40; P2 <- 0.33                      # control y tratamiento esperados
n_mas <- power.prop.test(p1 = P1, p2 = P2, power = 0.8)$n
c(MAS = ceiling(n_mas), DEFF2 = ceiling(2 * n_mas))              # por grupo
```

```
MAS DEFF2
742  1483
```

```r
ss4dp(N = 1e6, P1 = P1, P2 = P2, DEFF = 2, me = 0.03)$n.me       # margen de 3 puntos
```

```
[1] 3921
```

- `ss4dp()` / `ss4dm()`: diferencia de proporciones / medias (margen de error o CV), con traslape T y correlación R entre las mediciones.
- `ss4ddp()` / `ss4ddm()`: **dobles diferencias** (DiD). Con **panel** ($T = 1, R > 0$) el tamaño **baja**, porque la correlación entre línea de base y seguimiento reduce la varianza del cambio.

Tu turno

UNIVERSIDAD NACIONAL DE COLOMBIA
SEDE BOGOTÁ

Ejercicio.

1. Diseñe la evaluación del PAE: población objetivo, tratamiento, control, tiempos e indicador de impacto. ¿Qué método usaría si el programa ya cubre a todos los colegios oficiales?
2. En la simulación de DiD, haga que el grupo tratado crezca 1 punto más por periodo **antes** de la intervención. ¿Qué pasa con $\hat{\tau}$? ¿Cómo lo detecta en el gráfico?
3. En la RD, estime τ con $h = 5, 10$ y 20. Compare el estimador y su error estándar.
4. Calcule el tamaño de muestra por grupo para detectar una reducción de la deserción escolar del 15 % al 11 % (potencia 80 %) si se aleatoriza por colegios de 25 estudiantes con $\rho_y = 0{,}05$.

Referencias

Angrist, Joshua D., y Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Duflo, Esther, Rachel Glennerster, y Michael Kremer. 2007. «Using randomization in development economics research: A toolkit». En *Handbook of Development Economics*, vol. 4. Elsevier.

Gertler, Paul J., Sebastián Martínez, Patrick Premand, Laura B. Rawlings, y Christel M. J. Vermeersch. 2017. *La evaluación de impacto en la práctica*. Segunda. Banco Interamericano de Desarrollo y Banco Mundial.

Gutiérrez, Hugo Andrés. 2020. *samplesize4surveys: Sample Size Calculations for Complex Surveys*. https://CRAN.R-project.org/package=samplesize4surveys.

Ho, Daniel E., Kosuke Imai, Gary King, y Elizabeth A. Stuart. 2011. «MatchIt: Nonparametric preprocessing for parametric causal inference». *Journal of Statistical Software* 42 (8): 1-28.

Imbens, G. W., y D. B. Rubin. 2015. *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Vol. 84. Cambridge University Press.

Imbens, Guido W., y Thomas Lemieux. 2008. «Regression discontinuity designs: A guide to practice». *Journal of Econometrics* 142 (2): 615-35.

Londoño-Vélez, Juliana, Catherine Rodríguez, y Fabio Sánchez. 2020. «Upstream and Downstream Impacts of College Merit-Based Financial Aid for Low-Income Students: Ser Pilo Paga in Colombia». *American Economic Journal: Economic Policy* 12 (2): 193-227.

Diseño y Desarrollo de Encuestas — Universidad Nacional de Colombia

© 2026 Giovany Babativa-Márquez, PhD. Todos los derechos reservados.

Material elaborado con fines académicos para el curso Diseño y Desarrollo de Encuestas (2016363). Se apoya en Gutiérrez, A. — CEPAL (2023). *Diseño y análisis estadístico de las encuestas de hogares de América Latina*, Metodologías de la CEPAL N.º 5, y en Babativa-Márquez, J. G. (2026). *Diseño y Desarrollo de Encuestas Estadísticas* (manuscrito). Ejemplos con microdatos públicos del DANE (GEIH, ECV). Prohibida su reproducción total o parcial con fines comerciales sin autorización expresa del autor.